

测试时想象预算的自适应分配——完整技术简报

Benchmark / Baseline / 方法 / Gap / 突破口 全景 (PPT style)

Contents

0. 一页说清楚	2
Part I. 问题背景与动机	2
1.1 核心问题 (三个决策点)	2
1.2 为什么这个问题值得做——两组独立诊断证据	3
1.3 现有“想象”是两套完全不同的范式	4
Part II. Benchmark 全景	4
2.1 Benchmark 速查表	4
2.2 关键 benchmark 详解 (逐个说清楚“在测什么”)	7
Part III. 十一个最近邻方法逐一深度解析	8
3.1 AVIC ——最接近的整体框架, 但比较机制是“自治性”不是“决策价值”	8
3.2 FFDC ——最接近“何时停/何时该重新想”, 但只监控单条轨迹	10
3.3 Video-T1 ——想象内部的搜索结构最像, 但优化目标是生成质量不是决策价值	11
3.4 DreamerV3 ——训练时想象范式的代表, 不是测试时 controller 的直接竞品	11
3.5 Astra ——视觉推理场景下和 AVIC 最像的 2026 年新竞品, 资源背景更强	11
3.6 Imagine-then-Plan(ITP) ——和 idea 7“该不该想、想多深”重合度最高的框架级实现	14
3.7 ELASTIC ——扩散/流式控制策略的测试时算力调度, 不涉及想象但同属“自适应算力”家族	16
3.8 RARRL ——LLM 高层推理调用的开关 + 角色 + 预算三元决策, 消融最系统的一篇	18
3.9 Finding the Time to Think ——idea 7 最近邻, 但用完美模拟器 +MCTS, 非生成式 world model	20
3.10 ROI-Reasoning ——idea 7“跨步预算调度”机制上最接近的匹配, 但用于 LLM 批量数学推理	21
3.11 World-in-World ——idea 1“多候选比较”表层机制目前最强,ICLR 接收状态未证实	23
3.12 十一个方法一张总表	24
Part IV. 我们自己的三轮 Pilot 研究	26
4.1 实验设计 (贯穿三轮不变的骨架)	27
4.2 第一轮 (表格模型): 发现一/二	28
4.3 第二轮 (神经网络集成模型): 定性复现, 量级不同	28
4.4 第三轮 (task-conditioning): 三轮里第一次出现的正向发现	28
4.5 三轮 pilot 合起来的完整证据链 (经二次深挖后重新定位, 见 Part V)	28
Part V. Gap 分析: 最大的空当在哪里	29
5.1 一个必须先讲清楚的自我纠正	29
5.2 竞争格局: 半年内从近乎空白变拥挤	29
5.3 三条独立证据线收敛到同一个方法论空当	29

5.4 具体提案: 把经典二元 VOC 推广成 -渗透 VOC	30
Part VI. 我们要怎么才能超越现有 SOTA	31
6.1 不要走的路	31
6.2 具体的超越路径	32
6.3 需要正面回答的问题: 这是不是在给已经被判“理论风险大”的 idea 3 硬凑?	33
Part VII. 还未解决的问题	33
Part VIII. 时间线与开放问题	34
参考文献索引	34

0. 一页说清楚


给谁看: 这份文档写给 Song 和 Weikai, 目标是把这个研究方向“现在业界做到哪一步、我们瞄准什么问题、凭什么能做、要怎么做才能超过现在的水平”一次性讲透, 不需要临场再翻论文。**怎么读:** 每一节先给“要点”, 细节、公式、表格跟在要点后面。全部数字都标了出处 (论文 §/Table/Fig, 或本项目自己的 pilot 结果), 没有一个是凭空编的。11 个最近邻方法 (AVIC/FFDC/Video-T1/DreamerV3/Astra/ITP/ELASTIC/RARRL/Finding-the-Time-to-Think/ROI-Reasoning/ World-in-World) **全部逐字通读了完整 PDF 原文 (含附录), 不是读摘要**——这是本次二次深挖 明确要求做到的事。

三句话版本:

1. 我们要解决的问题——world model 在决策前“该不该想象未来、想几个候选、该信哪个、什么时候 停”——目前全行业都是训练前定死的常数或者靠 RL/GRPO 训练一个黑箱门控网络, 没有一篇工作给出 有理论保证的解法, 这是一个被三条独立证据线共同确认的方法论空当。
2. 半年内 (2026 年 2 月-7 月) 这个赛道从近乎空白变得拥挤——已经有 8+ 篇论文占据了“经验式门控”这条路的不同角落, 我们如果还走这条老路, 差异化会越来越难讲。
3. 我们自己的三轮 pilot 已经积累了这条新路 (理论驱动而非经验驱动) 所需要的数学基础和实证 calibration 数据, 提出的具体方向是把经典 Value of Computation 理论从“信息有没有”的 二元 假设, 推广成我们实测出来的“信息按通道、按程度连续渗透”的更真实情形。

Part I. 问题背景与动机

1.1 核心问题 (三个决策点)




1.2 为什么这个问题值得做——两组独立诊断证据

要点: 不是我们凭空猜“想象预算分配粗糙、经常帮不上忙”——这是两篇独立诊断性论文分别测出来的 硬数字，一篇测视觉推理场景，一篇测通用具身场景，方向完全一致。

证据 A (AVIC 论文自己的诊断, §3): 在 SAT-Real 数据集上人工把样本分四类 (数字来自原文 Fig.2a):

SAT-Real诊断集四类样本占比(AVIC论文Fig.2a)



类别	占比	含义
Unnecessary (Case 3)	54%	不调用世界模型也能答对, 想象是多余的
Helpful (Case 1)	14%	想象真正带来了正确答案
Misleading (Case 2)	9%	想象引入噪声 / 幻觉, 导致答错
All Failed	23%	想象与否都答错


即只有 14% 的情况想象真正帮上忙, 但现有 always-on(逢查必想) 策略对 100% 样本无差别调用世界模型。代价: always-on 想象比不想象只多拿到 4.6% 的准确率提升, 但要多花近两个数量级的 token、约 30 倍推理时间 (原文 §3)。“选择性想象上界” (先知式精确判断) 能把准确率从 baseline 62.0% → always-on 66.6% → 选择性上界 75.3%——这近 9 个点的差距就是“该不该想象判断准不准”能撬动的空间。

证据 B (Current Agents Fail to Leverage World Model as Tool for Foresight, arXiv:2601.03905, 2026.1, 已 WebFetch 核验): 更通用场景下的诊断, 原文具体数字: agent 模拟触发率低于 1%, 误用预测结果约 15%, 当模拟被强制使用时性能反而下降最多 5%。原文归因: 瓶颈在于 agent 缺乏“何时该模拟、如何解读预测结果、如何把预测整合进下游推理”这三方面能力。

两组数字互相独立验证同一个结论: 现有 agent 系统性地不知道该怎么用世界模型想象, 这不是 某一篇论文的孤例。

1.3 现有“想象”是两套完全不同的范式

要点: Dreamer 系列的“想象”是训练时机制, 不是测试时机制——部署时是一个纯 amortized policy, 不做任何决策时搜索。这和 MuZero/TD-MPC/我们要做的 controller 完全是两回事。



DreamerV3 原文 (arXiv:2301.04104) Critic learning 一节明确写道: “we select actions by sampling from the actor network **without lookahead planning**”。论文自己的 Atari100k 对照表 (Table 9) 里有一行“Online planning”属性, 横向对比 SimPLe/EfficientZero/SPR/IRIS/TWM/Dreamer 六个方法, 只有 EfficientZero (MuZero 系) 标 X, Dreamer 明确标“-”——论文自己就把两个范式区分开了, 不是 外部推断。

RSSM 公式 (原文逐字): Sequence model $h_t = f_\phi(h_{t-1}, z_{t-1}, a_{t-1})$; Encoder $z_t \sim q_\phi(z_t | h_t, x_t)$; Dynamics predictor $\hat{z}_t \sim p_\phi(\hat{z}_t | h_t)$ 。想象展开固定长度 $H=15$ (附录超参数表), 跨 150+ 任务同一套超参数不变, 零人工数据采到 Minecraft 钻石 (“out of the box with its default hyperparameters”)。

Part II. Benchmark 全景

要点: 这次深挖的 11 个最近邻方法一共用了接近 15 个不同的 benchmark/环境, 横跨视觉推理、导航、机器人操作、Agent 工具使用、实时游戏、数学推理五大类。下表是全景速查, 每个 benchmark 后面单独一段说清楚“是什么、测什么、数据什么样、现在最好成绩多少”。

2.1 Benchmark 速查表

Benchmark	所属方法	领域	任务类型	规模	主指标	当前最好成绩 (表内)
SAT-Real	AVIC	视觉空间推理 QA	单图 / 多图空间关系问答	诊断集 (§3)+ 主评测集	准确率%	AVIC-R 完整版最高 (见 Part III)
R2R	AVIC	视觉语言导航	序贯导航, 逐步门控	标准 R2R 验证集	Success Rate	见 Table 3(Part III)
MMSI-Bench	Astra	多图空间推理	跨图空间关系问答	1,000 条,6 类关系	EM 准确率%	闭源 Gemini-3-Flash+Astra-WM: 49.5
MindCube-tiny	Astra	3D 结构化空间推理	多视角空间推理	tiny 子集,3 类子任务	EM 准确率%	闭源 Gemini-3-Flash+Astra-WM: 72.7
RoboTwin(hard)	FFDC	机器人操作仿真	双臂协作操作任务	困难任务子集, 随机 / 干净两种场景	成功率%	FFDC: 76.40%(随机) / 76.00%(干净)
真实 Atribot S1	FFDC	真实机器人操作	25 自由度 → 应为 34 自由度 双臂操作	真实机器人试验	成功率%	FFDC: 80%
VBench	Video-T1	视频生成质量	多维度生成质量评测	标准 VBench 评测集	综合分 / 维度分	Pyramid-Flow(FLUX)+ToF: +5.86%
ALFWorld / WebShop / ScienceWorld / StableToolBench	ITP	文本 / 网页 Agent	家务 / 购物 / 科学实验 / API 工具调用	各自标准测试集	Success Rate	ITP 自适应 lookahead(见 Part III)
PushT / PushT-Obstacle	ELASTIC	机器人操作仿真	平面推物到目标位置	200 个固定初始条件	成功率 (散点图, 无数值表)	见 Part III 定性描述
Square PH / MH, Can Paired / Reverse	ELASTIC	机器人操作仿真 (Robomimic)	插销 / 抓取分拣	200 个固定初始条件	成功率 (散点图)	见 Part III 定性描述
LIBERO-10	ELASTIC	VLA 零样本迁移	10 个长时程操作任务	每任务 20 trial	成功率%+ 延迟	ELASTIC: 94.0%,BoN: 95.5%
真实 Franka+ 0.5	ELASTIC	真实机器人操作	双色杯子分拣	20 trial	成功率%	0.5 基线: 45%,ELASTIC 用 34% 更低延迟追平 BoN
ALFRED(AI2-THOR)	RARRL	具身指令跟随	导航 + 检视 + 取送 (自定义 3 类)	50 episodes / 类别	TSR% / 延迟 / token	RARRL: 82.7 / 76.4 / 69.5(三类)

Benchmark	所属方法	领域	任务类型	规模	主指标	当前最好成绩 (表内)
PacMan / Snake(Jumanji)	Finding-the-Time-to-Think	实时游戏	反应式生存游戏	100 episode 种子	累计得分	Gate: 2370(PacMan) / 16.54(Snake)
Real-time Tetris	Finding-the-Time-to-Think	实时游戏	20×10 消行	100 episode 种子	累计得分	Gate: 45.6, 最优 fixed: 27.6(+65%)
Speed Hex / Speed Go(pgx)	Finding-the-Time-to-Think	实时棋类	限时对弈	5 个共享时钟预算	平均期望得分	Gate: 0.58(Hex) / 0.59(Go)
GSM8K / MATH / AIME	ROI-Reasoning	数学推理	多题共享预算的序贯解题	5000 份合成试卷 ×2 难度档	Score(满分 3) / Regret	RARL: Hard / 512 下 0.93(超 GPT-4o-mini 3 倍)
AR / ImageNav / A-EQA / Manipulation(自建)	World-in-World	具身闭环任务套件	主动识别 / 图像目标导航 / 主动问答 / 操作	4 套件共上千 episode	SR% / SPL% / Ans.Score	见 Part III

2.2 关键 benchmark 详解 (逐个说清楚“在测什么”)

SAT-Real(AVIC): 视觉空间推理 QA, 给一张或多张图像 + 问题 + 候选答案, 要求回答需要空间想象力 的问题 (比如“如果相机往左转, 会看到什么”)。§3 的诊断实验是在这个数据集上人工标注四类样本 (见 1.2 节), 主评测在 Table 1(AVIC-R vs 各种策略模型 +baseline)。

MMSI-Bench / MindCube(Astra): 都是**已发表的外部 benchmark**(不是 Astra 自建),Astra 论文在这两个上做迁移评测。MMSI-Bench 1,000 条跨图空间推理样本,6 类参照物关系 (相机-物体/相机-区域/相机-相机/物体-物体/物体-区域/区域-区域);MindCube-tiny 是结构化 3D 环境里的多视角推理 子集。**重要提示**: 这两个 benchmark 上绝对分数最高的是闭源 Gemini-3-Flash(45.4/70.5 direct, 49.5/72.7 加 Astra-WM 强制想象后),Astra 的开源贡献是把 Qwen3-VL-8B 从 29.8/36.8 提升到 38.8/42.7, **不是绝对 SOTA**, 是“开源同规模模型里最强的自适应想象方案”。

RoboTwin + 真实 Atribot S1(FFDC):RoboTwin 是机器人操作仿真基准, 困难任务子集覆盖多种 双臂协作操作; 真实机器人是 Atribot S1(**34 自由度**, 此前简报误写成 25, 本次核实订正)。两个 场景 (随机/干净) 分别衡量在有干扰和无干扰条件下的鲁棒性。

ALFWorld/WebShop/ScienceWorld/StableToolBench(ITP): 四个文本/网页 Agent 标准 benchmark。ALFWorld= 家务任务文本环境,WebShop= 模拟网购环境,ScienceWorld= 科学实验交互环境, StableToolBench=API 工具调用评测。ITP 在全部四个上都验证了“自适应想象深度” 优于固定/随机预算。

LIBERO-10 + 真实 Franka(ELASTIC):LIBERO-10 是 10 个长时程机器人操作任务集合, 用来测 ELASTIC 在 SOTA VLA(0.5)checkpoint 上的**零样本**表现 (不重新训练, 只加测试时算力调度); 真实机器人 实验是自建的“两个颜色的杯子分拣” 任务, 0.5 基线成功率 45%, 主要失败模式是“紫杯离相机远时会 认错目标” 和“放置时够不到篮子边缘”。

ALFRED(RARRL): 标准具身指令跟随 benchmark, 基于 AI2-THOR 仿真器。**需要注意**:RARRL 论文 把结果按自定义的“Navigation/Inspection/Delivery” 三类汇报, **不是 ALFRED 官方标准的 7 类任务 划分**, 不能直接和 ALFRED 官方 leaderboard 对比, 是作者在自己动作空间下的内部对照。

PacMan/Tetris/Snake/Speed Hex/Speed Go(Finding-the-Time-to-Think): 五个“实时” 游戏环境, “实时” 具体体现为: 环境按固定帧率持续推进, 不管 agent 有没有想清楚; 想得越久,commit 步数越多, 世界变化越多。Tetris 是自建的 real-time 变体 (标准 Tetris 加了“重力持续下落、不等你想” 的约束)。Speed Hex/Go 是“限时快棋”,MCTS 每做一次模拟就消耗一格时钟。

GSM8K/MATH/AIME(ROI-Reasoning): 三个难度递增的数学推理数据集 (小学应用题 → 高中竞赛 → 奥数),ROI-Reasoning 把三题拼成一份“试卷”, 在严格全局 token 预算下要求依次解答, 测的是“预算 该怎么在多道题之间分配” 这个元认知能力, 不是单题推理能力本身。

World-in-World 四套件: 不是套用外部 benchmark, 是**自己新构造**的 4 个闭环任务 (基于已有 仿真器 Habitat-Sim/CoppeliaSim 和已有场景数据集 Matterport3D/HM3D 等), 因为论文的论点是“现有 benchmark 都是 open-loop 的, 没有一个测 world model 是否真的能在闭环任务里帮上忙”, 所以必须 自建。四套件:Active Recognition(主动识别被遮挡物体)、ImageNav(图像目标导航)、A-EQA(主动具身问答)、Manipulation(RLBench 4 任务)。

关于“现有 SOTA” 这件事需要向导师说明的共性问题:ELASTIC 和 RARRL 两篇论文都没有引用外部 文献的 SOTA 数字做对比, 只做了论文自己实现的几个 baseline 之间的内部对照 (固定预算/随机预算/ 启发式预算 vs 自己的

自适应方法)。这是这两篇论文一个客观的局限, 如果我们的工作要正面回应“和 SOTA 比怎么样”这个问题, 需要比它们做得更完整。

Part III. 十一个最近邻方法逐一深度解析


每个方法固定五段式: 问题定义 → 架构 (图 + 公式) → Benchmark 与结果 → 消融 → 局限性。全部基于逐字通读完整 PDF (含附录) 后整理, 不是转述摘要。

3.1 AVIC ——最接近的整体框架, 但比较机制是“自治性”不是“决策价值”

论文: Yu et al., *When and How Much to Imagine*, arXiv:2602.08236, 2026, UNC Chapel Hill+NTU。

问题定义: 视觉空间推理 QA 场景下, 该不该调用世界模型生成想象视角、调用多少次。

架构:



关键公式: 门控 + 规划一体化 (Eq.1) $(d, \pi) \sim \theta(d, \pi \mid I, q, A), d \in \{\text{skip}, \text{call_wm}\}$; 轨迹级验证 (Eq.2) $s^{(m)} = V(I, q, I_\pi^{(m)}), \pi^* = \arg \max s^{(m)}$ ——这 M 条候选轨迹全部来自同一策略对同一问题的独立重复采样 (self-consistency), 验证器选的是“这次采样质量最高的一次尝试”, 不是几个语义不同、后果不同的候选未来之间的决策价值比较; 训练目标 AVIC-R(Eq.4, GRPO) $r = \mathbb{1}_{\text{correct}} - c|\pi| - \beta_s \mathbb{1}_{\text{wrong-skip}} - \beta_p \mathbb{1}_{\text{parse-fail}}, c=0.1, \beta_s=\beta_p=0.5$ 。

结果: AVIC-R(Qwen2.5VL-7B) 平均每题只想象 **3.60 次** (vs always-on 基线 8.90 次), 准确率超过 GPT-4o 策略版本 (+8.0pp, 77.3% vs 69.3%), 略超 GPT-4.1(+0.7pp, 80.0% vs 79.3%, 原文未单独强调此项)。分类别: action-conditioned 类 +57.1%, dynamics-understanding 类只有 +28.5%。Table 6 消融: 去掉 wrong-skip 惩罚, 策略崩溃成全部 skip, 准确率 77.33%→62.67%(掉 14.66pp)。Table 4: 只做二元门控、不做动作长度自适应, 反而比 always-on 更差 (73.3% vs 77.3%)——**gating 和“想多少”必须联合优化**。R2R 导航实验 (Table 3) 证明能应用到序贯场景, 但每步 gate 决策彼此独立, 没有跨步骤预算调度。


局限性 (读完全文的判断): 验证器比较的是自洽采样不是真正的候选未来比较; reward 是 QA 正确性 代理不是显式 VOC 目标函数; 没有跨步预算调度。

3.2 FFDC ——最接近“何时停/何时该重新想”, 但只监控单条轨迹

论文: Wang et al., *When to Trust Imagination*, arXiv:2605.06222, 2026, 南方科技大学 + 港大 + Astribot。

问题定义: World Action Model(WAM, 骨干 Motus) 联合预测未来动作块和未来视觉 token 后, “已经预测的未来还能不能信” 要多久检查一次、什么时候该重新规划。

架构:



关键机制: 验证器只需编码最新一帧真实观测, 其余 (预测动作/视觉/语言) 全走 KV cache, 不需要重跑整个 WAM 就能算出置信度 (§3.2 “the verifier only encodes the latest real observation O_t and performs lightweight attention against these cached tokens...without rerunning the full WAM”). 训练是纯二分类: 正样本 = 真实成功轨迹片段, 负样本 = 失败轨迹 + 人工构造的“腐化”片段 (时间交换/夹爪翻转/后段加噪/尾部缩放)。

结果: RoboTwin 困难任务成功率 54.20%→**76.40%**(随机场景)、57.80%→**76.00%**(干净场景); 平均减少 WAM 前向调用 **69.10%**, 执行时间快 **34.02%**。真实机器人 (Astribot S1, **34 自由度**) 成功率 45%→**80%**, 但真实世界下平均调用次数和耗时反而略高于短 chunk 基线 (28.1 秒/16 次 vs 25.6 秒/14 次)——本身就是“该不该多算要按情况自适应”的直接证据。Table 3 消融: 去掉预测的视觉 token 输入, 准确率掉得最多 (76.4%→71.6%)——**想象出来的未来**


画面本身就是最有信息量的信号。

局限性: 只监控“已经生成的那一条想象轨迹”，不涉及生成多个候选未来、互相比较、挑一个采纳。

3.3 Video-T1 ——想象内部的搜索结构最像，但优化目标是生成质量不是决策价值

论文: Liu et al., *Video-T1*, arXiv:2503.18942, 2025, 清华 + 腾讯。

架构:



结果: PyramidFlow(FLUX) 上 Linear Search 需 5.22×10 GFLOPs, ToF 只要 1.62×10 (约省 3.2 倍, 实践简化情形下复杂度可到 $O(N+T)$, worst-case 仍是 $O(TN)$); NOVA 上约省 2.9 倍。VBench 提升: 多数模型 $+3.4\% \sim +5.9\%$ (相对提升百分比); OpenSora v1.2 提升幅度最小 ($+2.37\%$, 与 Table 2/Figure 6/ 正文结论一致——此前简报误引 Figure 2 图注符号笔误的“ -2.37% ”作负收益例子, 已订正)。

局限性 (三篇里差距最本质的一篇): verifier 打分依据是生成质量 (运动流畅度/语义对齐/美学质量), 整个流程完全没有下游决策任务的存在, 优化的是生成质量, 不是决策价值。

3.4 DreamerV3 ——训练时想象范式的代表, 不是测试时 controller 的直接竞品


论文: Hafner et al., arXiv:2301.04104, 2023 (Nature 2025)。列在这里是为了确立范式区分 (见 Part I §1.3), 不是方法竞争对手——它的“想象”发生在训练阶段产生 `-return`, 部署时不做 lookahead。用作后续所有“测试时想象”方法的历史参照系。

3.5 Astra ——视觉推理场景下和 AVIC 最像的 2026 年新竞品, 资源背景更强

论文: Zhu, Lin et al., *Thinking with Imagination*, arXiv:2606.06476, 2026.6, 港大 + 上海 AI Lab + SJTU + 复旦 + 北航。

问题定义: VLM 面对多视角空间推理任务时无法推断未观测布局——让 VLM 在推理中主动向一个 world simulator 发相机运动查询, 获得“想象出来的”新视角观测并整合进推理。

架构 (Astra-VL 策略 + Astra-WM 世界模拟器, 两阶段 RL 课程):



关键公式: 两阶段 RL 奖励。Phase 1(探索 + 工具获取): $r^{(1)} = r^{em} + \lambda_{fmt} r^{fmt} + \lambda_{use} \min(n^{tool}, c)$, 防止策略在学会调用前就坍缩成“直接短答案”。Phase 2(选择性 想象): 引入无工具基线估计增益 $\Delta_i = e_i - e_g^{direct}$, $r^{(2)} = r^{em} + \lambda_{fmt} r^{fmt} + \lambda_{use} \min(n^{tool}, c) + \alpha \max(0, \Delta_i) - \beta \max(0, -\Delta_i)$ ——只在模拟器交互 真的比直接回答更好时才奖励。

结果: MMSI-Bench All 从 backbone 的 29.8 提升到 **38.8**(+9.0pp); MindCube-tiny 从 36.8 提升到 **42.7**(+5.9pp)。**重要澄清:** 绝对分数最高的仍是闭源 Gemini-3-Flash(45.4/70.5 direct, 49.5/72.7 加想象), Astra 的贡献是“开源同规模最强”, 不是绝对 SOTA。两阶段课程消融 (Table 3): 单阶段只给工具增益奖励会让调用率坍缩到 4.9%; 只给使用量奖励会让调用率飙到 98.1% (几乎无差别想象); 完整两阶段课程平衡到 61.5% 调用率、拿到最高分 38.8。


局限性 (原文 Limitations 四点): 无恰当探索机制会坍缩到直接回答或过度使用模拟器; 模拟器可能生成“视觉上说得通但没用”的视角; 策略可能混淆原始图像和生成图像索引; 奖励是稀疏的精确匹配差值, 捕捉不到“部分有用”的观测。原文收尾判断: “tool use is neither a free reward nor a failure mode: it is an action whose value depends on the unresolved spatial uncertainty.”

3.6 Imagine-then-Plan(ITP) ——和 idea 7“该不该想、想多深”重合度最高的框架级实现

论文: *Imagine-then-Plan: Agent Learning from Adaptive Lookahead with World Models*, arXiv:2601.08955, 2026.3, 港理工 + 中南大学。

问题定义: LLM/VLM agent 每步该不该想象、想多深 (K_t)。

架构:



关键公式 (全部逐字核对 HTML 全文属实):POIMDP 形式化——“we move beyond POMDP toward a Partially Observable and Imaginable MDP (POIMDP)” ; 策略 $a_t \sim \pi_\theta(\cdot \mid s_t, \hat{\tau}_t(K_t))$; 伪标签选择准则 $\tilde{K}_t = \arg \max_{0 \leq k \leq K_{max}} [\log p_{\theta_0}(a_t^* \mid s_t, \hat{\tau}_t(k)) - \lambda_K \cdot k]$; 在线奖励 $r_{t+1} = r_{env} - \lambda_K K_t - \lambda_{step}$; 世界模型 $p_\phi(X \mid x_1, C(A))$ (token 级自回归文本生成, 不是隐空间动力学)。

结果:ALFWorld/WebShop/ScienceWorld/StableToolBench 四个 benchmark 全部验证——“fixed-k lookahead is brittle: success rate peaks at a moderate k then declines, cost rises sharply”、“adaptive lookahead achieves higher success rates with substantially lower budget”、“consistently outperforms random strategy”。


局限性 (需要向导师明确的三条差异化空间): 世界模型是微调文本 LLM, 不是隐空间动力学模型; horizon 一次性预先选定, 没有中途止损机制 (三阶段流程里没有提前终止的设计); 没有跨 episode 步骤的预算结转——这三点是仍然开放的具体空间。

3.7 ELASTIC ——扩散/流式控制策略的测试时算力调度, 不涉及想象但同属“自适应算力”家族

论文:Li, Swamy, Bisk, Bajcsy, *ELASTIC*, arXiv:2606.31132,2026.6,CMU。

问题定义: 生成式控制策略 (diffusion/flow policy) 在测试时可沿两条正交轴扩展算力——**序列轴** (增加去噪步数精细化单个动作) 和**并行轴** (并行采样多个候选、用 verifier 选优)。该往哪个轴砸算力是状态依赖的, 原文举反例: “mug pick-and-place 任务里, 若 base policy 不确定 该拿哪个杯子, 这本质是 mode selection 问题, 序列扩展基本没用, 更需要并行采样”。

架构 (Meta-MDP + SAC,Algorithm 1 完整伪代码):



关键公式 (核心奖励, 原文 Eq.1): $r(\xi) = Q^{task}(x, u) - \alpha L(\xi) - \beta(P(\xi) - 1)$, 其中 序列开销 $L(\xi) = \max_i \ell^{(i)}$ (最慢完成样本长度), 并行开销 $P(\xi) = \sum_i \ell^{(i)} / L(\xi) \geq 1$ (时间平均活跃样本数)。动作 $\Delta \tau^{(i)} = 0$ 定义为永久剪枝该样本, 使序列轴与并行轴 能在同一状态相关框架下联合优化。

结果: LIBERO-10 (SOTA VLA 0.5 checkpoint 零样本迁移)——ELASTIC 94.0% 成功率/64.5ms 延迟, 0.5 基线 91.5%/68.7ms, BoN 95.5%/94.0ms; “ELASTIC recovers performance gains equal to Sequential with 6.1% less inference latency”。真实机器人: **“ELASTIC can match the improvements of full BoN scaling with V-GPS while using 34% less inference latency”**。6 个模拟任务 (PushT/Square/Can 系列) 只有散点图定性趋势, **没有配套数值表**——这是本文一个 客观的呈现局限。


局限性 (原文照录): “the primary limiting factor for the effectiveness of our approach is the learned verifier Q_ϕ . A noisy verifier masks useful signal...hurting meta-policy optimization”; 且 “meta-policy is currently trained per task, which can be costly for multi-task policies like VLAs”。**没有传统意义的系统性消融表** (不像下面 RARRL)。

3.8 RARRL ——LLM 高层推理调用的开关 + 角色 + 预算三元决策, 消融最系统的一篇

论文: *When Should a Robot Think?*, arXiv:2603.16673, 2026, CMU+ 东北大学 + 哈佛等多机构。

问题定义: 具身系统调用 LLM 高层推理会带来巨大延迟, “该不该想、该用哪种推理角色、该分配 多少预算” 三个决策合一, 在决策层 (不是底层控制层) 学习一个编排 (orchestration) 策略。

架构 (Figure 1/2):



关键公式: 失败概率随推理增益调制 $P_{fail}^{think}(s, a) = (1 - \alpha(s))P_{fail}^{exec}(s, a)$, $\alpha(s) = \eta u(s)$ (η 固定环境参数, 不可学习, 只观测不确定性信号 $u(s)$)。PPO 目标 (Eq.1): $\mathcal{L}_{PPO}(\theta) = \mathbb{E}_t[\min(\rho_t \hat{A}_t, \text{clip}(\rho_t, 1 - \epsilon, 1 + \epsilon) \hat{A}_t)]$ 。预算等级到 LLM 调用的确定性映射: c=0 不调用; c=1 只调 planner (max_tokens=256); c=2 planner+verifier 依次调用 (各 max_tokens=512)。

结果 (ALFRED+AI2-THOR 真实 LLM 推理, 统计显著性检验): RARRL vs Full Reasoning—Navigation TSR 82.7 vs 84.0(略低) 但 LLM 推理时间从 31.5s 降到 **12.3s**(降 61%)、token 从 4100 降到 980; 三个任务类别 (Navigation/Inspection/Delivery) 均类似模式, 对应摘要“reduces LLM inference time by more than 60% while maintaining comparable task success”。抽象任务主结果 (Table II) RARRL 全面超过 Fixed/Heuristic/No/Full Reasoning 各项指标。Budget Shock 鲁棒性 (Table III): 资源突降后, Heuristic 基线推理调用次数不降反升 (14.2→15.1, 不会自适应), RARRL 主动降低 (11.3→7.6), 成功率保持更高 (74.9 vs 61.8)。

消融 (Table IV, 五项, 消融最系统的一篇): 去掉预算状态 b_t ——TSR 降 6.7pp、推理频率升 (缺资源 感知会过度调用); 去掉执行历史 h_t ——降幅最大; Planner-only(83.1) 优于 Verifier-only(79.4), 但都不如两者结合 (87.6); 固定预算 (禁用自适应)——成本升、成功率降。


局限性 (原文照录多条): 训练环境是“抽象/程序化的”, 不是物理仿真器或真实机器人, ALFRED 评测是训练后的**迁移测试**; 主动排除了传感器噪声与执行延迟 (“we isolate orchestration from sensor noise and actuation delays... extending the formulation requires incorporating such uncertainties”); 软预算约束非硬约束, 硬约束 (“via constrained MDPs or Lagrangian methods”) 留 未来工作; 推理有效性系数 η 是固定环境参数不可学习。

3.9 Finding the Time to Think —idea 7 最近邻, 但用完美模拟器 +MCTS, 非生成式 world model

论文: Muppidi, Darwish et al., arXiv:2606.26463, 2026.6, 牛津 (Foerster 组)。

问题定义: 实时 RL 中“思考本身要占用环境推进时间”——世界不会等 agent 想清楚, “该想多久”是状态依赖的元推理问题。

架构 (Budgeted Options + Meta-level SMDP):



关键公式: 元 Bellman 方程 (Eq.4) $V(s_t) = \mathbb{E}_{k \sim \pi_{gate}} [\sum_{j=0}^{k-1} \gamma^j r_{t+j} + \gamma^k V(s_{t+k})]$ 。GAE 的 holding-time 修正 (Eq.7-9, 防止长 budget 元步被系统性低估): $\delta_t = R_t + \gamma^{k_t} V(s_{t+k_t}) - V(s_t)$, $\hat{A}_t = \delta_t + \gamma^{k_t} \lambda \hat{A}_{t+1}$ 。

结果 (5 个环境, gate vs 最优 fixed baseline): Pac-Man 2370 vs 2149(+10.3%); Real-time Tetris 45.6 vs 27.6(+65%); Snake 16.54 vs 14.91(+10.9%); Speed Hex 0.58 vs 最优 fixed(k=128)0.43; Speed Go 0.59 vs 最优 fixed(k=64)0.51。原文: “random baseline falls well below every fixed-k policy...confirming that when to allocate compute matters as much as how much”。策略画像 (Appendix G, 可解释性亮点): Real-time Tetris 上 k=3 从未被使用 (0%), 形成“要么反应要么深规划”的双峰策略; Snake 上“刚吃到果实、身体刚变长”这一事件让 k=3 使用率从 3.2% 跳升到 13.5%。

局限性 (原文三点): 协议依赖 MCTS 对完美模拟器的忠实模拟, 扩展到 MuZero 式学到的动力学 模型是“natural future work”; 门控策略在冻结的 base planner 之上训练, 联合优化仍是开放 问题; 手工标定的离散 budget 集合。没


有任何形式化的收敛性/regret 理论保证。

3.10 ROI-Reasoning ——idea 7” 跨步预算调度” 机制上最接近的匹配, 但用于 LLM 批量数学推理

论文: Zhao, Qi, Sun, arXiv:2601.03822, 2026.1, 中国人民大学。

问题定义: 多题共享一个严格全局 token 预算, 该怎么在题目之间分配算力——形式化为 **Ordered Stochastic Multiple-Choice Knapsack Problem(OS-MCKP)**: 按固定顺序、在代价/收益都不确定的 情况下做不可逆决策。

架构 (两阶段:MFT 监督微调 + RARL 强化学习):



关键公式: 目标函数 (Eq.1) $\max_{\pi} \mathbb{E}[\sum_i r(\cdot)]$ s.t. $\sum_i c(\cdot) \leq B$. Dr.GRPO 目标 (Eq.4-5, 无 std 归一化的去偏版): $\hat{A}_{i,t} = R_i - \text{mean}(\{R_1, \dots, R_G\})$. regret 指标 (经验评测量, 非理论保证): $\widetilde{\text{Regret}} = (\text{Score}_{\text{easy}} - \text{Score}) / \text{Score}_{\text{easy}}$.

结果 (1.5B 模型 vs 百倍参数量大模型): 最亮眼的数字——**Hard/512(最难 + 最紧预算)** 设定下, **MFT+RARL 得分 0.93, 远超 GPT-4o-mini 的 0.32 和 DeepSeek-V3.2(685B) 的 0.49**. Regret 指标上 MFT+RARL 全面最优 (Medium/Hard 1024 档均为 0.02, 全表最低). per-problem 分解 (Table 2) 显示 baseline 方法在第三题 (P3) 准确率明显低于第一题 (P1), RARL 在 P2/P3 上提升幅度最大——学到的“是”为后面题目预留预算”的长程分配策略. Plan-and-Solve/Least-to-Most 这类**纯提示词**层面的 显式规划, 效果甚至差于 base model——说明必须靠训练干预, 不能只靠 prompt.


局限性: 聚焦固定 3 题的数学推理, 用 token 数代理成本 (不能完全捕捉延迟/工具调用/验证成本); 难度监督依赖粗粒度离散等级; **没有把经典 knapsack 理论的近似比结果迁移/证明到 RL 求解方案上**, regret 是经验近似指标不是理论保证.

3.11 World-in-World ——idea 1”多候选比较”表层机制目前最强,ICLR 接收状态未证实

论文: Zhang, Jiang et al., arXiv:2510.18135, 2025.10, JHU+PKU+Princeton+MIT 等.

问题定义: 现有 world model 评测都是 open-loop 的 (只看生成质量), 没有 benchmark 测”生成的世界是否真的能帮 agent 做出更好的闭环决策”.

架构 (policy-guided beam search, proposal→simulation→revision):



关键公式 (Eq.1-4): Proposal $\hat{A}_t^{(m)} \sim \pi_{\text{proposal}}(A | o_t, g)$; Simulation $\hat{O}_t^{(m)} \sim g_{\theta}(O | o_t, I_t^{(m)})$; Revision 一般形式 $D_t^* = \pi_{\text{revision}}(\{\hat{A}_t^{(m)}, \hat{O}_t^{(m)}\}, o_t, g)$; 打分-选择具体实现 $m^* = \arg \max_m S(\hat{A}_t^{(m)}, \hat{O}_t^{(m)} | o_t, g)$. **比经典 MPC 更通用**——MPC 优化对象被限制为动作序列, 这里 π_{revision} 可以合成/更新一个新决策.

结果 (4 个自建闭环任务套件, 不是套用外部 benchmark): Active Recognition 上闭源 Runway Gen4 (zero-shot) SR=64.79%(步数最少 4.06), 开源最好是 post-trained Wan2.2†(A14B) SR=62.43%; ImageNav 上开源最好 Wan2.1† SR=45.14%/SPL=32.10, Wan2.2†(A14B) SPL 全表最高 34.61; 操作任务上 最好后训练模型 SVD† SR=46.5%, 仅略高于 VLM 基线 44.5%(原文承认”精细物理动力学和动作条件化的物体运动仍是开放挑战”). **Scaling law 发现** (摘要重点, Figure 6): 后训练数据从 400 条扩到 80K 条, AR 成功率单调上升; 更大模型 (14B) 比小模型 (1.5B) 从数据增加中获益更多、更晚饱和——“scaling action-conditioned post-training is more effective for embodied utility than upgrading the pretrained generator”. 推理时算力 scaling (Figure 7): 每 episode 推理次数从 3 提到 11, SVD† SR 从 53.36% 升到 60.98%.

消融: “精细可控性比画面好看更重要” (Figure 5)——生成质量和 SR 之间没有干净正相关, 可控性 (1-LPIPS) 和 SR 才有明确正相关.

局限性 (Section 4 正文四点): 世界模型泛化能力是关键瓶颈 (可能退回训练先验、忽略动作控制); 长视野规划仍然困难 (缺乏积累时空历史的机制); 精确建模接触丰富交互 (操作任务) 仍然困难; proposal/revision 策略本身的强弱决定性能上限.

ICLR 接收状态——本次专项核实结果: 逐页通读完整 43 页 PDF(正文 + 参考文献 + 全部 6 个附录), **没有找到任何会议接收信息**——标题页只有普通 arXiv 日期戳, 没有“Published/Under review as a conference paper at ICLR” 横幅, 全文没有 Acknowledgments 段落, 附录逐一确认也无接收状态说明。**结论: 以这份 v1 PDF 为准, 无法确认 ICLR 2026 接收/Oral 状态, 读起来是标准 arXiv 预印本, 如需 在更正式场合引用接收状态, 需要另外查 OpenReview 或项目主页确认。**

3.12 十一个方法一张总表


方法	决策粒度	训练方式	理论保证	核心 benchmark	我们的差异化空间
AVIC	单次二元 gate+ 自治采样	RL(GRPO)	无	SAT-Real / R2R	真正决策价值比较 + 跨步预算
FFDC	单条轨迹信 / 不信	监督二分类	无	RoboTwin+ 真实机器人	多候选比较
Video-T1	树搜索剪枝 (生成质量)	verifier 打分	无	VBench	决策价值而非生成质量
Astra	单次二元 gate+ 自治采样	RL(两阶段 GRPO)	无	MMSI-Bench / MindCube	同 AVIC
ITP	每步选想象深度 K	RL(A2C)	无	ALFWorld 等 4 个	中途止损 + 跨 episode 结转
ELASTIC	去噪步数 + 并行采样	RL(SAC)	无	LIBERO-10+ 真实机器人	非 world model, 间接参照
RARRL	开关 + 角色 + 预算三元	RL(PPO)	无	ALFRED	非 world model, 间接参照
Finding-Time-to-Think	每元决策点选 k	RL(PPO)	无 (仅问题形式化严谨)	5 个实时游戏	生成式 world model+ 联合优化
ROI-Reasoning	每题解答深度 / 弃权	监督 +RL(Dr.GRPO)	无 (regret 是经验指标)	GSM8K / MATH / AIME	具身序贯决策场景
World-in-World	多候选提案比较	无 (启发式 / 预训练策略)	无	4 个自建套件	VOC 式反事实差值打分
我们要做的	三个决策点统一	理论驱动 + 训练估计	VOC / 最优停止 (目标)	合成 pilot+ 真实 world model	—

上表最右列“理论保证”一栏,11 篇里没有一篇打勾——这正是 Part V 要展开的核心论点。

Part IV. 我们自己的三轮 Pilot 研究

要点: 在提出任何新方法前,先在一个真实转移函数已知、可以精确算出“标准答案”的合成环境里,系统测量“想象到底什么时候真的有用”。三轮 pilot 分别测了三个递进的问题,每轮都预注册了预测,诚实报告 confirmed/disconfirmed。

4.1 实验设计（贯穿三轮不变的骨架）



4.2 第一轮 (表格模型): 发现一/二

扫想象深度 $H(K=5 \text{ 固定})$: 命中率 $44.0\%(H=1) \rightarrow 27.2\%(H=8)$, 决策改变率 $10.0\% \rightarrow 23.1\%$ 单调上升。扫候选数 $K(H=3 \text{ 固定})$: 决策改变率 $35.6\%(K=1) \rightarrow 10.0\%(K=10)$ 单调下降。

数学推导 (严格证明): 两个策略共享同一个不完美 LearnedWorldModel, imagination 的 rollout 续跑策略用贪心 V 、bootstrap 也用 V ——想象 rollout 的期望值会沿 Bellman 不动点方程精确 telescope 回 V 自己的一步展开值, 和 H 无关。可以用鞅的全方差公式进一步加强: 定义 $Y_t = \mathbb{E}[G_H | \mathcal{F}_t]$ 为条件期望过程, 这是一个鞅 ($Y_0 = \hat{Q}(s, a), Y_H = G_H$ 的实现值), 由全方差公式 $\text{Var}(Y_H) = \sum_{t=1}^H \mathbb{E}[\text{Var}(Y_t | Y_{t-1})]$ 严格非负、非递减——这解释了“ H 越深、决策改变率越高”这个观测模式是必然的方差累积, 不是巧合。

用 visit_count 当不确定性代理分组, 方向和预期相反 (高置信度组帮倒忙率 $0.149 >$ 低置信度组 0.058) ——推测是 value iteration 的 Bellman 误差跨状态传播导致局部访问次数不能直接反映 V 准不准, 呼应文献库 Biased Dreams(arXiv:2604.25416) 对不确定性代理需要独立验证的警告。

4.3 第二轮 (神经网络集成模型): 定性复现, 量级不同

换成 5 个 numpy 手写 MLP 的集成模型, 回答“发现一是否表格模型特有的巧合”。决策改变率恒定在 $65\% \sim 81\%$ 高位 (神经网络预测天然更“软”, 注入更多采样方差), 不是表格 pilot 的 $10\% \sim 36\%$ 量级; “ H 越深命中率越低”这个具体单调模式**没有复现**, 命中率的 H 依赖性证据比表格 pilot 弱。**member 模式** (想象采样时随机抽一个集成成员, 让想象看到基线看不到的集成分歧) **没有带来预期改善**——是条负结果, 把“多掌握信息必须是决策相关的”这条教训精确化: 随便什么新的随机性来源 (哪怕理论上是货真价实的 epistemic uncertainty) 都不够, 信息必须真的关于决策本身。集成分歧当不确定性代理, 方向上比 visit_count 更符合直觉 (低置信度组帮倒忙率 $0.480 >$ 高置信度组 0.388), 但样本量撑不住强结论。

4.4 第三轮 (task-conditioning): 三轮里第一次出现的正向发现

给想象一个真正决策相关的信息优势 (知道这一局真实任务目标, baseline 不知道)。三个候选目标上 命中率全部反超 (汇总 **82.0% vs 63.7%, +18.3pp, 零例外**)。过程插曲: 第一版代码有 bug (baseline 和想象共享同一个 Vhat 参数, 悄悄测的是同源结构), 数字和心智模型矛盾后定位修复, 如实记录在 RESULTS-task-conditioning.md。

意外发现: unconditioned 想象 (对照组) 命中率也比前两轮同源实验高很多 ($56.8\% \sim 72.5\%$ vs 前两轮 $30\% \sim 50\%$) ——推导原因是“即时奖励设计上总用真实目标计算、只有 bootstrap 过时”这个选择本身, 让更深的 rollout 在跌回过时 bootstrap 前先吃到更多真实目标奖励信号, 渗透程度随 H 增加。**这是全篇最重要的一条经验发现**: 给想象多少真实任务信息不是开关式的二元判断, 是连续的程度问题, 哪怕只开放“奖励可观测”这一个通道、不动 bootstrap, 想象也能捡到部分真实信号。

4.5 三轮 pilot 合起来的完整证据链 (经二次深挖后重新定位, 见 Part V)

同源想象 = 噪声 (有数学推导) 无关随机性救不回来 真正决策相关信息能稳定翻正、渗透程度连续可调。**重要: 不是新发现** (见 Part V §5.1), 是 1991 年 VOC 理论的推论; 经穷尽检索确认 无先例, 是三条里唯一站得住“新发现”这个说法的。

Part V. Gap 分析: 最大的空当在哪里

5.1 一个必须先讲清楚的自我纠正

我们 pilot 的发现一 (同源想象 = 噪声) 和发现二 (无关随机性救不回来), 核心原理正是 Russell & Wefald(1991) Value of Computation 停止法则的直接推论——“当所有可用计算的 VOC 都不为正, 立即 执行当前 belief 下的最优 action”, 数学上就是“ 计算不能改变决策则其期望价值恒为零”。这条已经被 Hay, Russell, Tolpin, Shimony 的 *Selecting Computations*(arXiv:1207.5879,UAI 2012, 已经 在我们自己的文献库里) 形式化到 Bayesian selection 问题层级。这次二次深挖新查到的 Grimm et al. *The Value Equivalence Principle*(arXiv:2011.03506,NeurIPS 2020)、Efroni et al. *Beyond the One-Step Greedy Approach*(arXiv:1802.03654,ICML 2018) 从另外 两个独立方向给出相同结论: 模型只要 value-equivalent 就足以支撑规划, 多步贪婪不天然具有 单调改进保证。**这意味着如果 idea 10 论文把核心贡献叙事锚定在发现一/二本身, 审稿人只要熟悉 这条文献脉络 (我们自己书架上就摆着最直接的先例), 几乎肯定会指出这是 reinvent the wheel.**

这不是说发现一/二没有价值: 我们做的是第一次在“ 测试时想象 + 现代世界模型” 这个具体场景里, 把一个 30 年前的抽象原理用严格数学 (鞅的全方差分解) 钉实、做出可复现的受控实验——这是合法的 **理论基线与阴性对照贡献**, 不是新发现。核心贡献叙事必须搬到发现三上。

5.2 竞争格局: 半年内从近乎空白变拥挤


Part III 的 11 个方法里,8 篇是 2026 年 1-7 月这半年内出现的 (Astra/ITP/ELASTIC/RARRL/ Finding-the-Time-to-Think/ROI-Reasoning/AVIC/FFDC)。这些论文两两技术细节不同, 但共同构成一个 “自适应测试时算力分配” 的密集聚类。头部大厂 (DeepMind/Meta FAIR/OpenAI/Berkeley RAIL/Stanford) 暂无直接证据参与这个具体问题, 风险低; 但中等资源学术组的聚集密度远超预期。7 月最新论文已经 开始转向失败诊断/综述 (如 Current-Agents-Fail), 暗示第一波“ 想象预算自适应分配” 方法论爆发期 可能已过峰值。

5.3 三条独立证据线收敛到同一个方法论空当

证据线 1(竞争格局的共性):Part III §3.12 总表最右列——11 篇方法没有一篇在“ 理论保证” 上打勾, 全部靠 RL/GRPO/PPO/SAC 训练一个经验式门控网络。


证据线 2(已经有人在摸, 但没碰到我们的场景): 这次核验到 Cognitive Friction(arXiv:2603.30031, 2026.3, 单作者 Davide Di Gioia) 用 HJB 启发的最优停止边界处理“ 该不该继续查询工具”, 但应用场景 是通用工具调用 agent, 完全没有涉及 world model/想象这个具体设定。这篇论文的存在证明理论化 方向不是死胡同, 只是还没人接到我们的问题上。

证据线 3(我们自己已经具备理论化叙事需要的实证基础): 发现一的 Bellman telescoping 论证本身 就是 VOC 理论在“ 同一模型多次采样” 这个特殊情形下的严格实例化; 发现三揭示了经典 VOC 理论一个没被 充分处理的维度——经典 VOC/最优停止理论普遍隐含假设信息优势是二元的, 而我们的实测表明信息 优势的渗透是连续、分通道的。



5.4 具体提案: 把经典二元 VOC 推广成 ϵ -渗透 VOC

给想象 rollout 涉及的每个信息通道 c (即时奖励/value bootstrap/转移模型/continuation policy) 赋一个渗透率 $\epsilon_c \in [0, 1]$, 表示这个通道携带了 baseline 不掌握的真任务信息的程度。 $\epsilon_c = 0$ (所有通道) 精确退化到发现一的 Bellman telescoping 结果——这不是被推翻, 是这个 更一般框架的一个特例。



我们三轮 pilot 其实已经是这个 空间里的几个采样点 (表格/神经网络 pilot 全部 $=0$; member 模式引入了一个 >0 但和决策无关的通道, 验证了“ >0 不等于 $VOC>0$ ”; task-conditioning pilot 是 ϵ_{reward} 恒为 1、 $\epsilon_{\text{bootstrap}}$ 从 0 变到 1 的一条轨迹, 63.7% 和 82.0% 是两个具体的 calibration 数据点)。需要形式化并检验的核心问题: VOC 作为 $\{\epsilon_c\}$ 和 rollout 深度 H 的函数, 具体函数形式是什么? 是否近似可加? variance 随 H 上升 (已证明) 和 bias 随 ϵ 上升这两者的权衡, 能不能给出理论上可求解或至少可数值刻画的最优停止深度 $H^*(\epsilon)$?


和 idea 7 的自然衔接: 如果 $\epsilon_c(t)$ 随 episode 推进、agent 观测越来越多而演化 (比如 关于“真实目标是什么”的 belief 随时间自然更新), “该在哪一步多想、哪一步省” 就能表述成一个关于 belief 更新的**序贯贝叶斯决策问题**, 而不是 ROI-Reasoning 式的 knapsack 硬约束或 ITP 式的每步独立选 K ——预算不是被显式“结转”的资源额度, 而是隐式体现在 belief 越确定、越不需要多想这个自然的信念 收敛过程里。这和现有三篇最近邻论文 (ITP/ROI-Reasoning/Finding-the-Time-to-Think) 的机制都 不同。

Part VI. 我们要怎么才能超越现有 SOTA

6.1 不要走的路

不要把方法贡献定位成“又一个 RL 训练的想象门控”。这条路已经拥挤 (Astra/ITP/AVIC 都在这条赛道), 资源更强的团队 (比如 Astra 背后的港大 + 上海 AI Lab) 会更快把它做大做全, 我们 2 个月的小团队在纯 经验式路线上没有速度优势。

6.2 具体的超越路径



1. **理论保证是 11 篇竞品共同缺失的维度**——不需要在“想象机制本身”上比谁的工程更精巧,只需要在“门控决策有没有可证的最优性/误差界”这一个维度上做到竞品都没做的事。
2. **受控 ground-truth 验证方法论是我们独有的资产**——11 篇竞品里,ELASTIC/RARRL 明确承认“没有引用外部 SOTA 做对比,只做内部对照”;我们的合成环境 + 精确 value iteration 裁判,是目前所有 11 篇论文里**唯一能够精确判断“想象选的动作是否真的更优”**的评测协议,这个方法论本身可以反过来验证/校准理论预测,形成“理论预测 vs 受控实测”的闭环——这是 11 篇里没有一篇做到的。
3. **task-conditioning pilot 的 calibration 数据已经是一个具体的、可扩展的锚点**——不是空谈“我们要做理论”,而是已经有 63.7%/82.0% 这两个真实数字可以拿来验证任何提出的 $VOC(\varepsilon, H)$ 函数形式对不对。
4. **信息通道分解这个视角,现有 11 篇论文没有一篇采用**——它们都把“该不该想”当一个整体决策,没有拆解“想象内部不同信息来源各自贡献了多少”。这个更细粒度的分解本身就是一个可以独立评估的贡献,哪怕理论部分推不出干净闭式解,也能作为消融研究的组织框架。


6.3 需要正面回答的问题: 这是不是在给已经被判“理论风险大”的 idea 3 硬凑?

不完全是。原判断“理论风险大”是因为没有具体、被逼出来的问题要证明,容易变成“为理论而理论”。现在的 -渗透 VOC 不是凭空提出的理论野心,是被自己三轮 pilot 的具体实证结果**倒逼**出来的一个具体、可证伪的延伸问题,而且有具体 calibration 数据点可以直接用来做初步函数形式拟合——这和“选一个理论框架往 already-decided 的方法上贴标签”是不同性质的工作。

Part VII. 还未解决的问题

1. **理论推导本身可能推不出干净的闭式解**——渐变信息 VOC 这个问题即使在经典决策论文献里也可能有已知的困难结果,2 个月内能不能拿到“哪怕不完美但站得住”的理论结果,是最大的不确定性。
2. **即使理论成立,“用网络估计通道级 $\varepsilon_c(t)$ ”这个训练目标本身需要重新设计**,理论优雅不等于实现容易。
3. **需要把 pilot 从 32 状态合成格子世界搬到真实 world model(DreamerV3/TD-MPC2)上重新验证**——高维环境里“通道”的定义本身可能更模糊。
4. **World-in-World 的 ICLR 接收状态、F2 组后 6 篇论文的逐字核验尚未完成**(见文档 03 的待办清单)。
5. **严格的“零信息泄露”三方对照组**(即时奖励也故意用默认目标算)仍未做,§4.4 的机制推导目前基于间接证据,不是独立实验验证。
6. **这次调研没有找到“渐变信息通道 VOC 延伸”这个具体理论问题的任何已有工作**,但这是“未找到”而非“确认不存在”的判断,不排除换个理论社区(信息论/控制论)搜索会有新发现。

Part VIII. 时间线与开放问题



需要会议明确拍板的问题 (汇总 Part V-VII 全部开放项):

1. -渗透 VOC 这个方向, 从理论背景判断 2 个月内拿到“哪怕不完美但站得住”结果的可行性有多高?
2. 如果理论路线可行, 是否需要收窄成“理论框架 + 合成环境验证”这一半, 真实 world model 验证作为 future work?
3. 如果理论风险太高, §6.2 第 4 点“消融研究框架”降级方案是否可以接受?
4. World-in-World 的 ICLR 接收状态、F2 组后 6 篇论文的逐字核验, 谁来做、什么时候做?
5. 10 个 idea 里最终选哪 1-2 个并行推进 (本文档不做决定)。

参考文献索引

11 个逐字通读全文 (含附录) 的核心方法论文: AVIC(2602.08236)、FFDC(2605.06222)、Video-T1(2503.18942)、DreamerV3(2301.04104)、Astra(2606.06476)、ITP(2601.08955)、ELASTIC(2606.31132)、RARRL(2603.16673)、Finding-the-Time-to-Think(2606.26463)、ROI-Reasoning(2601.03822)、World-in-World(2510.18135)。理论补强: Hay et al. Selecting Computations(1207.5879)、Grimm et al. Value Equivalence Principle(2011.03506)、Efroni et al. Beyond One-Step Greedy(1802.03654)、Cognitive Friction(2603.30031)、Sezener & Dayan(2002.04335)。诊断性证据: Current Agents Fail to Leverage World Model(2601.03905)。完整 88 篇文献库 (含 A-F 六个 track) 见 [papers/INDEX.md](#)。本文档所有事实性 claim 的核验记录见 [03-novelty-competitive-landscape.md](#)。