

World Model 测试时想象研究——新手向教科书式讲义

从强化学习基础到完整前沿地图：概念全解释·历史脉络·术语总表

Contents

0. 导读	2
0.1 这份文档和已有 5 份文档的关系	2
0.2 怎么读这份文档	4
Part 1. 十五个高频词速查表（先上路，不要求先背下来）	5
Part 2. 从零开始：强化学习与 World Model 是什么	7
2.1 强化学习 (RL) 的基本循环	7
2.2 World Model 是什么、为什么要有它	7
2.3 有了 World Model 之后能做两件完全不同的事	8
Part 3. 完整历史脉络:World Model 研究是怎么走到今天的	9
3.1 起点:2018 年, “World Models” 这个名字的由来	9
3.2 支线一: 隐空间想象训练策略——从 PlaNet 一路“刷题”到 DreamerV3	9
3.3 支线二: 学到的模型 + 现场搜索/规划——从 MuZero 到 TD-MPC2	11
3.4 支线三: 用视频生成模型直接当 World Model——想象开始变贵	13
3.5 三条支线在 2025-2026 年交汇: 生成式想象变贵, “该想多少” 成为新问题	14
Part 4. 关键区分再讲一遍: 训练时想象 vs 测试时想象	15
4.1 一个类比: 刷题 vs 开卷考	16
4.2 证据:DreamerV3 论文自己是怎么说的	16
4.3 为什么这个区分对我们的研究至关重要	17
Part 5. 完整前沿地图	17
5.1 前沿全景:68 篇文献怎么分类	17
5.2 两组独立诊断证据: 为什么说“想象预算分配得很粗糙”不是我们凭空猜的	18
5.3 十一个最近邻方法逐一深度解析	19
Part 6. 我们的研究定位: 从三轮 Pilot 到 ϵ-渗透 VOC	34
6.1 从零讲清楚: 什么是“计算的价值” (VOC)、什么是“最优停止”	34
6.2 我们自己的三轮 Pilot 实验	35
6.3 一次重要的自我纠正	37
6.4 三条独立证据线收敛到同一个方法论空当	38
6.5 具体提案: 把经典二元 VOC 推广成 ϵ -渗透 VOC	38
6.6 我们要怎么才能超越现有 SOTA	39
6.7 还未解决的问题 (如列出, 不回避)	41

Part 7. 时间线与开放问题	41
附录 A. 完整术语与缩写表	42
A.1 强化学习基础	43
A.2 World Model 专有概念	43
A.3 测试时计算与规划	44
A.4 不确定性与信息	44
A.5 训练算法	44
A.6 数学与理论工具	45
A.7 评测、会议与常见缩写	45
A.8 本项目自造术语 (pilot 实验专用)	46
参考文献索引	47

0. 导读

老师的原话：“进一步梳理 WM(World Model) 的研究整体脉络和完整前沿，写的东西得多名词解释和示意图，帮助新手研究者理解，不要假设读者是老手，看得懂密集的术语和缩写和著名工作，要像教科书那样详尽。”
这份文档就是对这句话的直接回应。


0.1 这份文档和已有 5 份文档的关系

在这份文档之前，项目已经产出了 5 份文档 (00-05)，它们的共同特点是**面向已经有背景的读者**——写给要开会讨论方向的 Song 和 Weikai，默认读者已经懂强化学习、已经知道 AVIC/Dreamer/MuZero 是什么，所以可以直接堆术语、堆公式、堆表格，把篇幅都花在“信息密度”上。这份新文档 (06) 反过来：**假设读者完全没有背景**，每一个术语第一次出现都会解释，每一个“这是什么/为什么这样做”都会讲清楚，代价是篇幅会更长，但目标是“一个人从头读到尾，不需要中途去查任何外部资料”。



两份文档不是谁取代谁:05 信息密度更高、更适合已经懂行的人快速对齐信息;06(本文档) 更适合第一次接触这个课题的人建立完整心智模型, 以后要查某个具体方法的公式/消融表格, 仍然可以 回到 05 或 papers/INDEX.md。

0.2 怎么读这份文档



全文结构:Part 1 给一张“高频词速查表”让你先上路, 不要求全记住;Part 2 从最基础的强化学习讲起, 建立“什么是 world model”这个核心概念;Part 3 是完整的历史脉络——world model 研究是怎么从 2018 年一路发展到今天的;Part 4 把“训练时想象”和“测试时想象”这两种范式的区别讲透 (这是理解后面一切内容的关键前提);Part 5 是完整前沿地图, 包括两组“想象经常没用”的诊断证据、十一个最近邻方法的逐一深度解析;Part 6 是我们自己的研究定位——三轮 pilot 实验、发现了什么、还有什么没解决、下一步准备怎么做;Part 7 是时间线;附录 A 是完整术语表, 可以随时翻回来查。

关于准确性: 全文所有数字、结论都标注了出处 (论文 §/Table/Figure, 或本项目自己的 pilot 结果代码和数据文件), 没有一个是凭印象转述的。历史脉络部分 (Part 3) 涉及的 9 篇经典论文, 本次专门重新逐篇核实了核心机制和关键数字 (不是从旧笔记里转抄)。

Part 1. 十五个高频词速查表（先上路，不要求先背下来）

导航提示：本 Part 之后依次是 Part 2(强化学习与 World Model 基础)、Part 3(完整历史脉络)、Part 4(训练时 vs 测试时想象——关键区分)、Part 5(完整前沿地图)、Part 6(我们的研究定位)、Part 7(时间线)、附录 A(完整术语表)。


这张表只是“先给你一个锚点”，完整解释在 Part 2-6 正文里，完整术语表在附录 A。第一次读到不熟悉的词，可以先回来扫一眼这张表，继续往下读，不需要现在就完全理解。

词	一句话是什么
强化学习 (RL)	一个“智能体”通过不断试错、根据反馈调整行为,学会在某个环境里达成目标的机器学习范式
环境 (Environment)	agent 所处的世界——可能是真实机器人、游戏、仿真器,agent 的每个动作都会让它发生变化
状态 (State) / 观测 (Observation)	当前时刻环境的样子 (比如一张画面、一组传感器读数)
动作 (Action)	agent 可以对环境做的操作 (比如“向左走一步”)
奖励 (Reward)	环境对 agent 动作的反馈,一个数字,agent 的目标是让长期累积奖励最大
策略 (Policy)	agent 用来决定“这个状态下该做什么动作”的规则 / 网络
World Model(世界模型)	一个学出来的、能预测“做了某个动作后环境会变成什么样”的模型——不是真实环境,是环境的一个近似替身
想象 / Rollout	不在真实环境里行动,而是在 world model 里“模拟”接下来会发生什么,这个模拟过程就叫“想象”或“rollout”
Model-based / Model-free RL	有没有用到 world model 这个“替身”——用了叫 model-based,直接在真实环境里试错学策略叫 model-free
规划 (Planning)	在采取真实动作之前,先用 world model 在脑内“预演”几种可能性,挑最好的那个
测试时计算 (Test-time compute)	部署 / 使用阶段 (而不是训练阶段) 额外花费的计算量,比如多想几步、多生成几个候选
不确定性 (Uncertainty)	模型对自己预测有多大把握的量化指标,把握越小说明这个预测越可能是错的
消融实验 (Ablation)	把方法里的某个部件去掉 / 换掉,看效果掉多少,以此证明这个部件确实有用
SOTA	State-of-the-Art, 当前公开报告里最好的效果
VOC(计算的价值)	Value of Computation, 量化“多算一步”到底值不值得的经典理论框架,本项目的核心数学工具

Part 2. 从零开始：强化学习与 World Model 是什么

2.1 强化学习 (RL) 的基本循环

一个强化学习问题总是由一个“智能体” (agent) 和一个“环境” (environment) 组成。Agent 观察当前状态, 选一个动作执行, 环境根据这个动作变化到新状态并给一个奖励信号, agent 根据这个反馈调整自己下次怎么选动作——这个循环不断重复, agent 的目标是让长期累积奖励尽可能大。



一个具体例子: 把这个循环套到“格子世界” (gridworld, 本项目自己的 pilot 实验用的就是这个)——agent 是格子里的一个点, 状态是它当前所在格子, 动作是“上下左右移动一步”, 奖励可能是“走到终点 格子得 +1 分, 撞墙 0 分”。Agent 一开始完全不知道该怎么走, 靠不断尝试、记住“在这个格子往这个方向走能拿到更好的结果”, 逐渐学会一条好路线。


数学上, 这个循环通常写成一个 MDP (Markov Decision Process, 马尔可夫决策过程): 一个五元组 $(\mathcal{S}, \mathcal{A}, P, R, \gamma)$ ——状态集合 $\mathcal{S}$ 、动作集合 $\mathcal{A}$ 、转移函数 $P(s' | s, a)$ (在状态 s 做动作 a 后跳到状态 s' 的概率)、奖励函数 $R(s, a)$ 、折扣因子 $\gamma \in [0, 1)$ (未来的奖励打几折, 越小说明 agent 越“短视”、只在乎眼前)。“Markov” 这个限定词的意思是: 转移到下一个状态只依赖当前状态和动作, 不依赖更早的历史——这是一个简化假设, 如果环境本身部分不可观测 (比如 agent 看不到完整棋盘, 只能看到自己视野范围内的一角), 就要用 POMDP (Partially Observable MDP, 部分可观测马尔可夫决策过程) 来建模, 这个概念在 Part 5 讲 ITP 论文的 POIMDP 变体时会再用到。

价值函数 (Value Function): $V(s)$ 衡量“从状态 s 开始, 按某个策略走下去, 长期能拿到多少期望累积奖励”; $Q(s, a)$ 是更细一级的版本, 衡量“在状态 s 先做动作 a , 之后再按策略走下去”能拿到多少期望累积奖励。这两个函数在本文档后面 (尤其 Part 6 讲我们自己的 pilot 时) 会反复出现——我们 pilot 实验能做“精确裁判”的关键就是格子世界足够小, 可以用 value iteration (价值迭代, 一种直接对 Bellman 方程反复做不动点迭代直到收敛的经典算法) 精确算出真实的最优 $Q^*(s, a)$, 不需要靠采样估计, 这是很多真实世界任务做不到的“奢侈条件”。

2.2 World Model 是什么、为什么要有它

想象你在学开车。Model-free (无模型) 的学法是: 坐进真车里, 不断试错——猛打方向盘看看会怎样、急刹车看看会怎样, 靠真实世界给的反馈 (有没有撞车) 慢慢学会开车。这个学法的问题是: 试错成本很高 (真的会撞车), 而且每一次尝试都要真的花时间在真实世界里发生一遍。

Model-based (有模型) 的学法是: 先在脑子里建立一个“这辆车会怎么反应”的心智模型——打方向盘多少度车头会转多少角度、刹车距离大概多长——然后在脑子里先演练几种驾驶方案, 想清楚了再真正操作方向盘。这个“脑子里的心智模型”, 在强化学习里就叫 world model (世界模型): 一个学出来的、能回答“如果在状态 s 下做动作 a , 环境会变成什么样 (下一个状态 s')、会给多少奖励 r ”这个问题的近似模型, 记作 $\hat{P}(s' | s, a)$ 、 $\hat{R}(s, a)$ (符号上加个“帽子”表示“这是模型的估计, 不是环境真实的规则”)。



有了这个“替身”以后,agent 就可以在**不用付出真实代价**的情况下,反复“想象”很多种可能性——这个想象的过程,就是本项目标题里“想象”(imagination)这个词的来源,技术上通常叫 **rollout** (把一个想象出来的轨迹“卷”出来、展开出来的意思):从当前状态出发,用 world model 连续预测 若干步之后环境会怎样,形成一条“想象轨迹” $\hat{s}_1, \hat{s}_2, \dots, \hat{s}_H$ (H 是想象了多少步,叫 **horizon**,是本项目通篇反复出现的一个关键变量)。

2.3 有了 World Model 之后能做两件完全不同的事

这是全篇最重要的一次概念铺垫,Part 4 会专门展开讲。这里先埋一个伏笔:“**想象**”这个能力,可以用在**两个完全不同的时间点**——

1. **训练阶段用:** 在学策略的过程中,大量使用 world model 生成的想象轨迹当“练习题”,练出一个策略网络。练完之后,部署时这个策略网络直接凭直觉出动作,不再需要 world model、不再做任何现场想象——就像一个练习了几千道类似题目的学生,考试时凭训练出来的直觉秒答,不再需要在考场上重新演算。
2. **测试(部署)阶段用:** 每次真的要做出决策之前,现场调用 world model 想象几种可能性,比较完再选一个——就像开卷考试,每道题当场翻书、当场演算,现算现用。

本项目研究的问题,完全属于第二种: 一个 agent(或者更准确地说,一个已经训练好的系统)在**部署时**,**每次要做决策的这一刻**,该不该临时调用 world model 想象一下、该想几个候选、该想多深、想完之后该不该信——这四个问题合起来就是“测试时想象预算的自适应分配”这个研究问题的完整表述。

Part 3. 完整历史脉络:World Model 研究是怎么走到今天的

这一 Part 专门核实的 9 篇经典论文:World Models、PlaNet、Dreamer(v1)、DreamerV2、MuZero、TD-MPC、TD-MPC2、Genie、GameNGen——全部逐页重新读了本地 PDF 原文,不是从旧笔记转抄,也不是凭印象转述。每一段都标了精确的引用位置 (§/Table/Figure)。

3.1 起点:2018 年,“World Models”这个名字的由来

论文:Ha & Schmidhuber, *World Models*, arXiv:1803.10122, 2018.5(这份 PDF 本身是一份 arXiv 预印本,没有在文中标注具体会议或期刊名称)。

这篇论文把智能体拆成三个部分,名字直接就叫 V、M、C:

- **V(视觉)**: 一个 VAE(变分自编码器), 把每一帧 64×64 像素的图像压缩成一个 32 维的小向量 z ——相当于给图像做了一个“精简摘要”。
- **M(记忆)**: 一个 MDN-RNN(混合密度网络 + 循环神经网络), 根据历史预测下一个 z 可能是什么样——注意是“可能”,不是“一定”: 它输出的是好几种可能性的加权组合(比如“大概率前方安全,但也有一点点小概率有障碍物”),这样能表达环境本身的不确定性,而不是武断地只给一个“标准答案”。
- **C(控制器)**: 一个极其简单的线性层,直接把 z 和 M 的隐藏状态映射成动作——在 CarRacing 赛车任务里,C 的全部参数只有 867 个,而且不是用梯度下降训练的,是用一种叫 CMA-ES 的进化算法训练的(每一代随机撒一批参数、挑表现好的、让下一代往这个方向靠拢)。

这篇论文最有名的地方,要分两种情形讲清楚,不能混为一谈:

1. CarRacing 赛车任务:C 是在**真实环境**里训练的(V、M 只是固定住不变的特征提取器),最终跑到 906 ± 21 分(100 次试验平均,论文称是当时第一个“解出”这个任务的方法,§3.3, Table 1)。
2. VizDoom “Take Cover” (生存类小游戏): 这才是**完全在梦境里训练、几乎零真实环境交互**的经典案例——先用随机策略在真实 VizDoom 里跑 1 万条轨迹,训练出 V 和 M,之后 C 的全部训练都在 M 生成的虚拟环境(“梦境”)里完成,论文原文明确写道“we have not actually attempted to train our agent on the actual VizDoom environment”(附录 A.5)。练完直接把策略搬回真实 VizDoom 测试,反而拿到 1092 ± 556 分(100 次试验,超过 750 分的“解出”门槛,§4.2-4.4, Table 2)。

这篇论文在“**想象预算**”这个问题上的立场: 完全没有 Dreamer/MuZero 那种显式的“想象 horizon”或“搜索次数”超参数——梦境 rollout 的长度就是任务本身的 episode 上限(VizDoom 是 2100 步),真实环境和虚拟环境用同一个上限。唯一被系统调过的量是 MDN-RNN 采样时的“温度”参数(控制梦境里的不确定性大小),论文手动试了几个值(0.10/0.50/1.00/1.15/1.30)挑出效果最好的 1.15(Table 2)——这是训练前人工选定、之后不再变化的常数,没有让预算随状态/难度自适应的机制。

3.2 支线一: 隐空间想象训练策略——从 PlaNet 一路“刷题”到 DreamerV3

这条支线延续 Part 4 已经讲过的“训练时想象”范式: 用 world model 生成大量想象轨迹当练习题,训出一个策略网络,部署时不再现场想象。



PlaNet(Hafner et al., 2019 ICML,arXiv:1811.04551): 学一个 RSSM(循环状态空间模型, 后面 Dreamer 系列沿用了同一个结构) 之后, 用 CEM(交叉熵方法, 一种“撒一批随机方案、挑最好的一批、在这批附近继续撒点”的搜索算法) 在隐空间里挑动作——**规划视界 $H = 12$ 、每轮 采样 1000 条候选、迭代 10 轮、每轮保留表现最好的 100 条** (附录 A, 全部 6 个测试任务共用 同一套超参数)。效果上, 平均只用约 200 倍更少的真实环境交互, 就能打平当时更强的 model-free 方法 (不同任务具体倍数不同, 从 40 倍到 500 多倍不等, Table 1)。**论文自己在第 7 节明确把“用一个价值函数估计规划视界之外的回报”列为未来工作**——也就是说 PlaNet 完全没有用价值函数弥补“只看 12 步”的局限, 是硬截断, 这一点后来正是下面的 TD-MPC 补上的。

Dreamer / Dream to Control(Hafner et al., 2020 ICLR oral,arXiv:1912.01603): 在 §4.2 已经详细讲过 RSSM 结构和“没有现场规划”这件事。这里补一个关键的历史事实:**Dreamer 不是在隐空间里做现场搜索 (像 PlaNet 那样), 而是把价值估计的梯度直接反向传播穿过整条想象 轨迹去更新策略网络**——这比传统强化学习靠采样估计梯度方向的做法更高效。20 个 DeepMind Control Suite 连续控制任务上, Dreamer 只用 500 万步真实环境交互就拿到 823.39 分, 而 同样用 500 万步的 PlaNet 只有 332.97 分, 用 1 亿步 (20 倍数据量) 的强 model-free 方法 D4PG 也只有 786.32 分 (附录 G 表格)——**用远少的真实环境交互超过了当时最强的 model-free 方法, 这是“想象 轨迹拿来训练”这条路线第一次在这个规模上证明自己好用**。论文 Figure 4 的消融实验也很有启发性: 如果去掉价值函数 (想象到 H 步就截断, 不再往后 估计), 效果对 H 的选择非常敏感; 但完整版 Dreamer (想象到 H 步后用价值函数续接估计 剩余回报) 对 H 的选择相当稳健——**这篇论文某种意义上的核心贡献, 是“用价值函数把对想象 预算长度的依赖降下来”, 而不是“让预算自适应”**, 这两者是不同的思路, 但为“想象要多长才够”这个问题提供了目前看来最早的系统对比数据。

DreamerV2(Hafner et al., 2021 ICLR,arXiv:2010.02193): 和 Dreamer(v1) 最大的技术 差异是把隐变量从连续的高斯分布, 换成了**离散的 categorical 分布** (32 个类别变量、每个 32 类, §2.1)——这个改动让模型能更干脆地表达“环境要么是那样、要么是那样”这种离散的可能性, 在实践中效果更好。想象展开长度仍然是 $H = 15$, 和 Dreamer(v1) 一样 (附录 D)。这是第一个“纯粹依靠一个独立训练出来的世界模型学习行为”、并在 55 款 Atari 游戏上达到人类水平的方法 (需要注意: 这个“第一” specifically 指“model-based 这一类方法里的第一个”, 不是史上第一个超过人类基准线的算法, 当时已有的 model-free 方法 Rainbow/IQN 也早已超过)。同样是全部 55 款游戏共用一套超参数, 没有自适应机制。

DreamerV3(Hafner et al., 2023, 后于 2025 年发表于 *Nature*,arXiv:2301.04104): 已经在 Part 4 §4.2 详细讲过——延续 $H = 15$ 这个固定值, 靠一系列“鲁棒化技巧” (归一化、KL 平衡等) 让**同一套超参数能跨 150 多个完全不同的任务通用, 而且第一次做到“零人工数据、默认超参数”就能在 Minecraft 里采到钻石** (这是一个公认很难的长程稀疏奖励任务)。DreamerV3 是目前这条支线里最强的通用 world model, 但它的“想象预算分配粗糙”这个问题, 和 PlaNet 一样 一以贯之地存在——只是随着模型越来越强、任务越来越通用, 这个问题被越来越强大的鲁棒化技巧 掩盖了, 没有被直接解决。

3.3 支线二: 学到的模型 + 现场搜索/规划——从 MuZero 到 TD-MPC2

这条支线是“测试时想象”范式 (Part 4 讲过的第二种模式) 最主要的历史来源——每次真实决策前, 现场用学到的模型做搜索或轨迹优化。

MuZero(2019,后于2020
发表于Nature)DeepMind

不需要知道游戏规则,
自己学一个隐动力学模型
MCTS树搜索,棋类800次/
Atari 50次模拟(固定值)

同属'学到的模型+
现场搜索/优化'范式

TD-MPC(2022 ICML)

任务导向隐动力学模型
(不重建画面)+MPPI规划
H=5,候选512条
可学习终值函数补偿短视界

TD-MPC2(2024 ICLR)

H=3(比TD-MPC更短!)
候选512条,精英64条
同一套超参数跨104个任务
'去除按任务调参'本身是卖点


MuZero(Schrittwieser et al., DeepMind, arXiv:1911.08265,2019, 后于 2020 年发表在 *Nature*): 和更早的 AlphaZero 最大的区别是——AlphaZero 搜索时用真实规则模拟器 (比如围棋规则本身) 推演“这样走棋盘会变成什么样”;MuZero 完全不知道游戏规则, 而是学一个“隐动力学模型”来自己“编造”这套推演逻辑, 只包含三个函数: h (把历史观测编码成 初始隐状态)、 g (给定上一个隐状态和一个假想动作, 直接吐出预测的即时奖励和下一个隐状态, **全程不生成任何图像**)、 f (从隐状态直接读出策略和价值)。搜索用 MCTS(蒙特卡洛 树搜索: 反复从根节点出发, 按一个平衡“探索新分支”和“利用已知好分支”的打分公式往下走, 走到没展开过的叶子就用模型评估一下, 再把结果沿路径回传更新沿途节点), 但整棵搜索树完全 在学出来的隐空间里展开, **从不调用真实环境**。**关键数字: 每次搜索的模拟次数是固定 常数——棋类游戏 (围棋/国际象棋/将棋)800 次, Atari(因为动作空间小得多)50 次 (§4, 附录 C)。**结果: 围棋上用比 AlphaZero 更小的网络还略微超过 AlphaZero;Atari 57 款 游戏上人类归一化得分中位数 2041.1%(Table 1)。论文自己做的消融实验 (Figure 3) 特别 值得注意: 训练时只用 800 次模拟, 测试时把“思考时间”一路加到 50 秒 (远超训练时的规模), 学到的模型依然能很好地泛化——**这说明“要不要想这么久”当时完全是研究者手动设定、观察 效果画图, 而不是模型自己决定的**;全部 57 款 Atari 游戏上把模拟次数从 1 扫到 500, 性能提升在约 100 次后趋于平坦。

TD-MPC(Hansen, Wang, Su, 2022 ICML,arXiv:2203.04955,UC San Diego): 提出“任务 导向的隐动力学模型” (TOLD)——不要求模型学会重建完整画面 (没有 decoder), 只要求学会 “预测” 对任务奖励有用” 的量, 这样能避开阴影、纹理这些和任务无关的视觉细节带来的建模负担。决策时用 MPPI(一种和 CEM 类似、靠加权平均迭代优化候选动作分布的规划算法) 在隐空间 做**模型预测控制** (MPC: 规划一整段动作序列, 但只真的执行第一步, 下一步重新规划)——但 **只规划很短的视界, 默认 $H = 5$ 、候选轨迹数 512**(加 5% 来自策略先验), 同时联合训练一个“终值函数”来估计这短短 5 步之后一直到无穷远的长期回报, 补偿短视界规划本身看不到的未来 收益——这正是上面 PlaNet 自己承认没做到的那件事。有一个有意思的训练期细节: 训练早期会把 规划视界从 1 线性增长到 H (因为模型一开始不准, 想太远没有意义)——但这是**训练阶段的 课程式调度**, 不是部署时按状态/任务难度做的自适应。

TD-MPC2(Hansen, Su, Wang, 2024 ICLR,arXiv:2310.16828): 相比 TD-MPC, 最大的升级 是**鲁棒性**——只用同一套超参数就能横跨 4 个不同领域共 104 个任务稳定工作 (TD-MPC 需要 按任务类别手调), 而且验证了模型可以放大规模: 训出一个 317M 参数的单一智能体, 跨 80 个 任务通用, 不同任务的机器人形态、动作空间都不一样。**核心规划预算参数 (附录 Table 8): 视界 $H = 3$ (比 TD-MPC 的 5 还要短!)、候选轨迹数 512、精英数 64**——论文原文明确说“启发式自动设置”只适用于折扣因子和“种子步数”这类外围超参数, **规划预算真正的核心旋钮 (视界/候选数/精英数) 对全部 104 个任务完全一样, 是训练前定死的常数**。论文把“去除按 任务调参”本身当作一个卖点——这对我们项目关心的问题 (想象预算该不该自适应分配) 是一个 非常直接的反例参照: 业界最新最鲁棒的隐空间规划方法, 选择的方向恰恰是“让预算更加一刀切”, 而不是“让预算更加自适应”。

3.4 支线三: 用视频生成模型直接当 World Model——想象开始变贵

前两条支线里的“想象”, 都发生在一个抽象的、低维的“隐空间”里, 不需要真的生成一张能看懂的 画面。第三条支线不一样: 直接用能生成逼真画面/视频的生成模型 (扩散模型、自回归 Transformer 等) 本身充当 world model——**这条支线的画面质量、可解释性远超前两条, 但代价是一次“想象”的算力开销急剧上升, 这正是“该想多少”这个预算问题从“理论上存在”变成“实际上不得不面对”的关键转折点。**




Genie(Bruce et al., 2024, Google DeepMind, arXiv:2402.15391): 完全从无标注的互联网 2D 平台游戏视频 (筛选后 680 万个 16 秒片段、约 3 万小时) 里训练出一个“可交互”的虚拟环境, 不使用任何人工标注的动作标签。模型由三部分组成: 时空视频 tokenizer(把画面压缩成一串离散代码)、**隐动作模型** (训练时“偷看”当前帧和下一帧, 自己总结出仅有 **8 种** 离散的隐藏“动作”——相当于模型自己发明了一套手柄按键, 不需要人告诉它“这是向左走”)、基于 MaskGIT 的自回归动态模型 (根据历史帧和隐动作预测下一帧)。总参数约 107 亿 (摘要笼统称“11B”)。**关键局限**: 论文自己在结论部分承认“Genie currently operates around 1FPS” (目前大约每秒 1 帧), 远不够支撑实时交互体验, 被列为未来工作。每帧固定用 25 步 MaskGIT 去噪, 是训练前定死的常数, 不随画面复杂度调整。

这里有一个需要向读者坦白的核实细节: 关于“Genie 是 2024 年 ICML 最佳论文之一”这个说法, 本次重新核实这份 arXiv PDF 全文时**没有找到任何标注这项荣誉的文字**——这份 PDF 读起来就是一份标准的 DeepMind 技术报告/arXiv 预印本。如果确实需要在正式场合引用这个荣誉信息, 应该另外核实官方获奖公告, 不能只凭这份 PDF 断言。

GameNGen(Valevski et al., 2024 投稿, 2025 正式发表于 ICLR, Google, arXiv:2408.14837): 用一个扩散模型 (基于 Stable Diffusion v1.4 改造) 直接“预测”下一帧 DOOM 游戏画面应该长什么样, 不是传统游戏引擎那样按规则渲染——训练分两阶段: 先用强化学习 (PPO) 训练一个 agent 学会玩 DOOM 并录下它的操作轨迹, 再用这些录像训练扩散模型模仿“根据过去几帧画面 + 过去几次按键, 预测下一帧”。**这是“为赶预算牺牲生成质量”最具体的一个历史证据**: 为了达到实时帧率, 论文把扩散模型通常需要的“几十步”去噪, 硬压缩到只用 **4 步 DDIM 采样** (DDIM 是扩散模型里一种可以用更少步数完成去噪的采样方法)——论文自己的消融表 (Table 1) 显示, 4 步和 64 步的画面质量几乎没有差别 (PSNR 32.58 对比 32.19), 但如果进一步压到 1 步 (且不做额外的蒸馏优化), 质量明显下滑 (PSNR 降到 25.47)。最终配置下单块 TPU-v5 能跑到 **20FPS**, 精确的延迟分解是: 4 步去噪的神经网络计算共 40 毫秒, 加上自编码器 10 毫秒, 总共 50 毫秒/帧。人类评委在 1.6 秒/3.2 秒的短片里分辨“这是真游戏还是生成的”, 正确率只有 58%/60% (接近瞎猜的 50%)。这 4 步的去噪预算, 是一次性消融测试后拍板的全局常数, 不管画面是空荡走廊还是激战中的复杂场景, 统一都是同样的 4 步、同样的 40 毫秒——这正是“预算怎么分配”这个问题留下的空白: 论文自己都推测出了“为什么 4 步就够”的原因 (图像空间本身受限 + 前序帧提供了强约束), 但这个洞察只停留在事后解释, 没有被用来做“根据画面内容自动增减去噪步数”这件事。

3.5 三条支线在 2025-2026 年交汇: 生成式想象变贵, “该想多少”成为新问题

把三条支线放在一起看, 能看到一条清晰的脉络:



三条支线共同指向同一个尚未被彻底解决的问题: **不管是隐空间里的“想象”(支线一、二) 还是 画面级的“想象”(支线三), 想象预算——该想多久、想几个候选、该不该想——几乎从 2018 年一直到 2024 年, 都是训练前人工调好、之后固定不变的常数。**区别只在于, 支线三里“想象”本身变得肉眼可见地贵 (GameNGen 为了实时不得不砍掉 90%+ 的去噪步数), 这种“贵”倒逼整个领域在 2025-2026 年开始密集出现专门研究“该怎么省着点用这份想象能力”的新方法——这就是 Part 5 要详细展开的“完整前沿”。

Part 4. 关键区分再讲一遍: 训练时想象 vs 测试时想象

为什么要专门用一整个 Part 来重复这件事: 这是 2026-07-20 会议简报撰写过程中的一次重要修正——读 DreamerV3 论文原文之前, 曾经笼统地把“Dreamer 系列”和“MuZero/我们的问题”归为同一类“会想


象的 world model 方法”，读完原文才发现这是两个范式完全不同的东西。这个误解具有代表性——不熟悉这个细分领域的人几乎都会踩这个坑，所以值得单独用一个 Part、配一个类比，讲到不会再错。

4.1 一个类比：刷题 vs 开卷考

刷题式学习（对应“训练时想象”）：考试前，学生疯狂刷几千道类似的练习题，把解题套路练成肌肉记忆。**考试当场不能翻书、不能演算太久**，拿到题目要凭训练出来的直觉迅速作答。

开卷考试（对应“测试时想象”）：每道题拿到手，当场翻书、当场在草稿纸上演算几种解法，比较完选一个最有把握的答案再写上去。**平时不需要刷太多题，但考试现场要花时间“现算”**。

World model 的“想象”能力，在这两种模式下扮演的角色完全不同：



4.2 证据:DreamerV3 论文自己是怎么说的

这不是我们的推断，是 DreamerV3 论文 (Hafner et al., arXiv:2301.04104,2023, 后于 2025 年发表在 *Nature*) 原文明确写的。在讲 critic 怎么训练那一节，原文逐字写道：

“we select actions by sampling from the actor network **without lookahead planning**”
(我们通过从 actor 网络里采样来选择动作，**不做任何前瞻式规划**)

论文自己的 Atari100k 结果对照表 (Table 9) 里有一列专门叫“Online planning” (在线规划，即“部署时是否做现场搜索”)，横向对比了 SimPLe、EfficientZero、SPR、IRIS、TWM、Dreamer 六个方法——**只有 EfficientZero(属**

于 MuZero 一脉) 这一列标了 X(表示“是”),Dreamer 这一列明确标的是“-”(表示“否”)。也就是说,这个范式区分不是外部研究者强行归类出来的,是论文作者自己在表格里就分得清清楚楚的。

RSSM 是 Dreamer 系列 world model 的具体结构 (RSSM = Recurrent State-Space Model, 循环 状态空间模型), 原文给出的核心公式 (逐字照抄):

- Sequence model(序列模型, 负责把历史信息压缩进一个隐状态里): $h_t = f_\phi(h_{t-1}, z_{t-1}, a_{t-1})$
- Encoder(编码器, 把真实观测压缩成隐变量): $z_t \sim q_\phi(z_t | h_t, x_t)$
- Dynamics predictor(动态预测器, **不看真实观测**、只靠历史隐状态预测下一个隐变量——这就是“想象”发生的地方): $\hat{z}_t \sim p_\phi(\hat{z}_t | h_t)$

训练阶段,DreamerV3 会用 dynamics predictor 连续展开固定长度 $H = 15$ 步 (超参数写在附录表里, 跨 150 多个不同任务全部沿用同一套超参数不变), 生成大量“想象轨迹”来训练 actor-critic; 但一旦训练完成、部署使用时, 上面那句“without lookahead planning”就意味着——**这个 15 步的想象展开能力, 在部署阶段完全没有被使用。**


4.3 为什么这个区分对我们的研究至关重要

我们要解决的“该不该想象、该想几个候选、该想多深、该不该信”这四个决策, **只有在“测试时想象”这个范式下才有意义**——如果 world model 只在训练阶段用来生成练习题 (像 Dreamer 那样), 那么“部署时该不该想象”这个问题根本不存在, 因为部署时压根不会再调用 world model。所以本项目从 Part 5 开始要深入分析的“最近邻方法” (AVIC、FFDC、Astra、ITP.....), 清一色都属于“测试时想象”这个范式——它们和 Dreamer 系列的关系, 更准确的说法是“研究问题不同、不是直接竞争对手”, 而 MuZero、TD-MPC 这类“学到的模型 + 现场搜索/轨迹优化”的方法, 才是我们问题在概念上最直接的“远房亲戚” (Part 3 会讲清楚它们各自是怎么发展出来的)。

Part 5. 完整前沿地图

5.1 前沿全景:68 篇文献怎么分类

项目的完整文献库 (见 [papers/INDEX.md](#)) 一共 68 篇标注清单 (61 篇 arXiv 论文 + 7 篇没有 arXiv 版本的经典引用), 分成 6 组 (A-F)。**不需要记住每一篇**, 但需要建立一个“这 6 组分别在回答什么问题”的整体地图——这是“完整前沿”这四个字真正的意思: 不是罗列书单, 而是知道每一类文献在整个论证链条里扮演什么角色。




怎么读这张图:A、B 两组回答“这个问题真实存在、而且很重要”(A 组证明预算目前分配得很粗糙, B 组证明想象这件事本身很贵, 粗糙分配的代价很大);C、D 两组是“工具箱”——别的领域(比如 LLM 推理 加速里的投机解码)已经有一些解决类似结构问题的技术, 可以借鉴过来;E 组是“理论武器库”——Value of Computation(计算的价值, 后面简称 VOC)这套 30 年前就有的经典理论, 是本项目从头到尾 最核心的数学工具;F 组是这次二次深挖 (2026-07) 专门找的、**和我们研究问题最直接竞争的 11 个 2026 年新方法**, 是 Part 5.3 要逐一深度解析的对象。

5.2 两组独立诊断证据: 为什么说“想象预算分配得很粗糙”不是我们凭空猜的

要点:这不是一句“我们觉得现有方法不够好”的空话, 是两篇独立诊断性论文分别测出来的硬数字, 一篇测视觉推理场景, 一篇测通用具身场景, 结论方向完全一致。

证据 A (AVIC 论文自己的诊断实验, 原文 §3): 在 SAT-Real 数据集 (一个需要“空间想象力”才能 答对的视觉问答数据集, 比如“如果相机往左转会看到什么”) 上, 论文作者把样本人工分成四类:

SAT-Real诊断集四类样本占比(AVIC论文Fig.2a)



类别	占比	含义
Unnecessary(不必要)	54%	不调用世界模型、直接看原图也能答对, 想象是多余的
Helpful(有帮助)	14%	想象真正带来了正确答案
Misleading(误导)	9%	想象引入噪声 / 幻觉, 反而导致答错
All Failed(都答错)	23%	想不想都答错

也就是说, 只有 14% 的情况下想象真正帮上忙, 但现有的“always-on”(逢查必想, 不做任何判断) 策略对 100% 的样本都无差别调用世界模型——付出的代价是:always-on 比完全不想只多拿到 4.6 个百分点的准确率提升, 但要多花近两个数量级 (约 100 倍) 的 token、约 30 倍的推理时间 (原文 §3)。如果换成一个“先知式”、每次都精确判断该不该想的上界

策略, 准确率能从 baseline 的 62.0% 一路推到 **75.3%**——这中间将近 9 个百分点的差距, 就是“该不该想象这个判断准不准”这一件事能撬动的真实空间。

证据 B(*Current Agents Fail to Leverage World Model as Tool for Foresight*, arXiv:2601.03905,2026.1, 已 WebFetch 核验): 场景更通用 (不局限于视觉问答), 原文报告的具体数字——agent 主动触发模拟的比例**低于 1%**, 即使触发了、误用预测结果的比例约 **15%**, 当研究者强制 agent 使用模拟结果时, 性能反而最多下降 **5%**。论文把原因归结为 agent 缺乏三方面能力: **判断何时该模拟、如何解读模拟出来的预测结果、如何把预测结果整合进下游推理**——这三条其实正好对应本项目“该不该生成/该不该采纳/什么时候停”这三个决策点里的前两个。

两组数字来自完全不同的团队、完全不同的任务场景, 却不约而同地指向同一个结论: **现有 agent 系统性地不知道该怎么用 world model 这个“想象”能力**, 这不是某一篇论文的个别现象。

5.3 十一个最近邻方法逐一深度解析


怎么读这一节: 每个方法都会先给一个“这篇论文要解决什么问题”的一句话概括, 再给架构图和关键公式 (公式看不懂可以先跳过, 不影响理解整体思路), 最后给“和我们的差异化空间在哪”。全部十一篇论文**都是逐字通读了完整 PDF 原文 (含附录)**, 不是只读摘要——这是 2026-07-22 二次深挖时定下的规矩, 详见每个方法段落里标注的 §/Table/Figure 出处。

先修提示: 读这一节之前, 建议先确认自己理解了 Part 4 的“训练时想象 vs 测试时想象”区分——下面十一个方法 (除了作为历史参照的 DreamerV3) **全部属于“测试时想象”这个范式**。

5.3.1 AVIC ——最接近的整体框架, 但比较机制是“自洽性”不是“决策价值”

论文: Yu et al., *When and How Much to Imagine*, arXiv:2602.08236,2026,UNC Chapel Hill+NTU。

一句话问题定义: 视觉空间推理问答场景下, 该不该调用世界模型生成“想象出来的”新视角画面、调用多少次。



术语卡片: 自洽性采样 (Self-Consistency) ——让同一个模型对同一个问题独立重复采样多次 (比如采样 5 遍), 再从这 5 次尝试里挑一个“看起来最靠谱”的答案。这和“生成 5 个语义不同、后果不同的候选方案再比较”是两件不同的事——前者是同一个方案的多次独立尝试 (靠“多数表决”或“打分挑一次质量最高的尝试”), 后者才是真正的“决策价值比较”。这个区分是理解 AVIC 局限性的关键。

关键公式: 门控 + 规划一体化 (原文 Eq.1) $(d, \pi) \sim \theta(d, \pi \mid I, q, A)$, 其中 $d \in \{\text{skip}, \text{call_wm}\}$; 轨迹级验证 (Eq.2) $s^{(m)} = V(I, q, I_\pi^{(m)})$, $\pi^* = \arg \max_m s^{(m)}$ ——这 M 条候选轨迹全部来自同一策略对同一问题的独立重复采样 (self-consistency), 验证器选的是“这次采样质量最高的一次尝试”, 不是几个语义不同、后果不同的候选未来之间的决策价值比较; 训练目标 AVIC-R (Eq.4, 用 GRPO 这种强化学习算法训练) $r = \mathbb{1}_{\text{correct}} - c|\pi| - \beta_s \mathbb{1}_{\text{wrong-skip}} - \beta_p \mathbb{1}_{\text{parse-fail}}, c=0.1, \beta_s=\beta_p=0.5$ 。

术语卡片: GRPO ——Group Relative Policy Optimization, 一种强化学习训练算法 (PPO 的变体, 最早因 DeepSeek-R1 而广为人知), 核心思路是“对同一个输入采样一组候选输出, 组内比较相对好坏来算优势值”, 不需要额外训练一个价值网络。本文档后面还会遇到 PPO、SAC、Dr.GRPO 等同类算法, 都是“用采样到的经验数据、按某种规则更新策略网络参数”这个大类下的具体配方, 细节差异不影响本文档的理解, 可以都当作“训练门控策略用的强化学习算法”来读。


结果: AVIC-R (用 Qwen2.5VL-7B 模型) 平均每题只想象 **3.60 次** (相比 always-on 基线的 8.90 次), 准确率超过 GPT-4o 策略版本 (+8.0 个百分点, 77.3% vs 69.3%), 略超 GPT-4.1 (+0.7pp, 80.0% vs 79.3%)。原文 Table 6 消融实验: 去掉“错误地选择跳过”这一项惩罚, 策略会直接崩溃成“全部跳过不想象”, 准确率从 77.33% 掉到 62.67% (掉 14.66 个百分点)。原文 Table 4: 如果只做“要不要想象”的二元门控、不联合优化“该想多深”, 效果反而比 always-on 更差 (73.3% vs 77.3%)——这说明“**该不该想**”和“**该想多少**”这两个决策必须联合优化, 不能拆开单独做。R2R 导航实验 (Table 3) 证明这套机制能应用到“一步一步走”的序贯场景, 但每一步的 gate 决策彼此独立, 没有跨步骤的预算调度 (比如“这一步先省着点, 留着预算给后面更难的路口用”)。

局限性 (逐字读完全文后的判断): 验证器比较的是同一策略的自洽采样, 不是真正不同后果的候选未来之间的比较; 训练用的奖励信号是“这题答没答对”的代理, 不是显式的 VOC 目标函数; 没有跨步骤的预算调度机制。

5.3.2 FFDC ——最接近“何时该停/何时该重新想”, 但只监控单条轨迹

论文: Wang et al., *When to Trust Imagination*, arXiv:2605.06222, 2026, 南方科技大学 + 港大 + Atribot (一家做人形机器人的公司)。

一句话问题定义: 一个叫 World Action Model (WAM) 的系统同时预测“接下来要做的动作”和“接下来会看到的画面”, 这个“已经预测好的未来”能信多久? 该多久检查一次、什么时候该放弃、重新规划?



关键机制: 验证器只需要重新编码“最新这一帧真实观测”，其余（之前预测的动作/画面/语言指令）全部走 **KV cache**（一种复用之前算过的中间结果、不用重新从头计算的工程技巧，LLM 推理加速里 非常常见）——不需要重跑整个 WAM 大模型，就能算出这一刻的置信度（原文 §3.2 逐字：“the verifier only encodes the latest real observation O_t and performs lightweight attention against these cached tokens...without rerunning the full WAM”）。训练方式是纯二分类：正样本是真实成功的 轨迹片段，负样本是失败轨迹 + 人工构造的“故意破坏过”的片段（比如时间顺序打乱、机械臂夹爪状态 翻转、后半段加噪声）。

结果: RoboTwin(机器人操作仿真基准) 困难任务成功率从 54.20% 提升到 **76.40%**(随机场景)、从 57.80% 提升到 **76.00%**(干净场景); 平均减少 WAM 前向调用 **69.10%**，执行时间快 **34.02%**。真实机器人 (AstriBot S1, **34 自由度**) 成功率从 45% 提升到 **80%**，但真实 世界下平均调用次数和耗时反而略高于短 chunk 基线——这本身就是“该不该多算需要按具体情况自适应”的一个直接证据。原文 Table 3 消融：去掉“预测的未来画面”这个输入，准确率掉得最多 (76.4%→71.6%)——说明**想象出来的未来画面本身，就是最有信息量的信号**，不是可有可无的装饰。

局限性: 只监控“已经生成的那一条想象轨迹”够不够可信，不涉及一次生成多个候选未来、互相比较、挑一个采纳——这正是下一篇 Video-T1 和后面 AVIC 想解决但方式不同的问题。

5.3.3 Video-T1 ——想象内部的搜索结构最像，但优化目标是生成质量不是决策价值

论文: Liu et al., *Video-T1*, arXiv:2503.18942, 2025, 清华 + 腾讯。

一句话问题定义: 视频生成模型能不能像 LLM 的“测试时扩展” (test-time scaling, 多想一会儿 换更好答案) 一样，靠多花计算量换更好的生成视频质量？



术语卡片：树搜索 / 剪枝 (Pruning) ——把“生成一整段视频”拆成一步步的树形分支（比如“先生成首帧的几个候选，选出有希望的几支，再往下展开中间帧”），每一步只保留有希望的分支、提前砍掉明显不行的分支（这就叫“剪枝”），而不是等所有分支全部生成完再一次性比较——这样能省下大量算力，是“预算该怎么花”这个大问题在视频生成场景里的一个具体解法。

结果：在 PyramidFlow(FLUX) 这个视频生成模型上，朴素的 Linear Search 需要 5.22×10^7 GFLOPs 的算力，Tree-of-Frames 只要 1.62×10^7 (省了约 3.2 倍)；VBench(一个综合评测 视频生成质量的标准评测集) 上多数模型有 +3.4%~+5.9% 的相对提升。

局限性 (和我们的问题差距最本质的一篇)：打分器 (verifier) 依据的是**生成质量**（画面运动 是否流畅、是否符合文本描述、美学质量如何），整个流程里完全没有“下游决策任务”的存在——优化的 是“这段视频好不好看/像不像”，不是“这段想象对做决策有没有帮助”。这个区分非常重要：Video-T1 的“想象”服务于生成质量，我们的“想象”服务于决策价值，是两件目标完全不同的事，即使搜索结构（树形剪枝）看起来很像。

5.3.4 Dreamer V3 ——训练时想象范式的代表，不是测试时 controller 的直接竞品


论文：Hafner et al., arXiv:2301.04104, 2023 (后于 2025 年发表在 *Nature*)。

已经在 Part 4 详细讲过——它的“想象”发生在训练阶段（生成练习题训练 actor-critic），部署时不做任何现场规划。放在这里，是为了确立后面所有“测试时想象”方法的历史参照系，不是一个方法上的竞争 对手。

5.3.5 Astra ——视觉推理场景下和 AVIC 最像的 2026 年新竞品，资源背景更强

论文：Zhu, Lin et al., *Thinking with Imagination*, arXiv:2606.06476, 2026.6, 港大 + 上海 AI Lab+SJTU+复旦 + 北航。

一句话问题定义：视觉语言模型 (VLM) 面对“多个视角拼起来的空间推理题”时，常常推不出没有被直接观测到的房间布局——能不能让它在推理过程中，主动向一个“世界模拟器”发一个“如果相机往 这边转会看到什么”的请求，拿到想象出来的新视角画面，再整合进推理过程？



关键机制：两阶段强化学习课程训练。第一阶段先让模型学会“愿意主动调用工具”（否则模型会倾向于偷懒直接短答案、不去调用模拟器）；第二阶段才开始奖励“调用模拟器确实比直接回答更好”这件事本身，引入一个“无工具基线”作对照——只有当“调用模拟器”的效果真的超过“不调用直接回答”的效果时才给奖励，不是“调用了就有奖励”。


结果：在 MMSI-Bench(多图空间推理评测集) 上，总分从骨干模型自身的 29.8 提升到 **38.8** (+9.0 个百分点)；在 MindCube-tiny(3D 结构化空间推理评测集) 上从 36.8 提升到 **42.7** (+5.9pp)。**需要特别澄清的一点：**这两个评测集上绝对分数最高的仍然是闭源模型 Gemini-3-Flash(45.4/70.5 不加想象直接答,49.5/72.7 加想象后)——Astra 的贡献是“开源同等规模模型里最强的自适应想象方案”，不是刷新了整体最高分。原文的两阶段消融实验显示：如果只给“工具调用有没有带来增益”这一种奖励，策略会几乎不再调用模拟器（调用率坍塌到 4.9%）；如果只给“用了工具就有奖励”这一种，调用率又会飙到 98.1%（几乎每次都调、和不做判断没区别）；完整的两阶段课程才能平衡到 61.5% 的调用率，拿到最高分。

局限性（原文自己列出的四条）：缺乏恰当的探索机制时会坍塌成极端策略；模拟器有可能生成“看来说得通、但其实没帮助”的画面；策略有时会混淆“这是原始图像”还是“这是生成出来的想象画面”；奖励信号是稀疏的“答对/答错”差值，捕捉不到“这次想象部分有用”这种中间状态。

5.3.6 Imagine-then-Plan(ITP)——和“该不该想、想多深”重合度最高的框架级实现

论文：*Imagine-then-Plan: Agent Learning from Adaptive Lookahead with World Models*, arXiv:2601.08955,2026.3, 港理工 + 中南大学。

一句话问题定义：一个 LLM/VLM agent 每一步该不该想象、该想多深（用 K_t 表示这一步想象展开的步数）？



术语卡片:POMDP $\rightarrow$ POIMDP ——前面 Part 2.1 提到过 POMDP(部分可观测马尔可夫决策过程)。ITP 论文提出了一个变体叫 **POIMDP**(Partially Observable and Imaginable MDP, 部分可观测且可想象的马尔可夫决策过程)——在标准 POMDP 基础上, 显式加入“agent 除了观测真实环境, 还可以调用 world model 生成一段虚拟轨迹辅助决策”这个额外能力, 这是把“想象”这件事写进决策过程正式数学定义里的一种方式。

关键公式 (全部逐字核对论文 HTML 全文属实): 策略 $a_t \sim \pi_\theta(\cdot | s_t, \hat{\tau}_t(K_t))$ (动作依赖当前状态和“想象出来的轨迹”); 用来训练“该想多深”这个判断的伪标签 选择准则 $\tilde{K}_t = \arg \max_{0 \leq k \leq K_{max}} [\log p_{\theta_0}(a_t^* | s_t, \hat{\tau}_t(k)) - \lambda_K \cdot k]$ ——直白地说, 就是“在所有候选想象深度里, 挑一个‘让正确动作 概率最高’和‘想象步数代价’加权后最划算的深度, 当作训练目标”; 在线奖励 $r_{t+1} = r_{env} - \lambda_K K_t - \lambda_{step}$ (环境本身的奖励, 减去想象步数的代价, 再减去 每步的固定代价)。

结果: 在 ALFWorld、WebShop、ScienceWorld、StableToolBench 四个标准 agent 评测集上全部 验证了同一个结论——原文原话: “fixed-k lookahead is brittle: success rate peaks at a moderate k then declines, cost rises sharply” (固定想象深度很脆弱: 成功率会在某个中等深度达到峰值后 反而下降, 而代价一直在涨); “adaptive lookahead achieves higher success rates with substantially lower budget” (自适应想象深度能用更低的预算拿到更高的成功率)。

局限性 (需要明确的三条差异化空间): 世界模型是微调过的文本 LLM(靠生成文字来“想象”), 不是 隐空间动力学模型; 想象深度是**一次性预先选定的**, 过程中没有“发现想错了、提前止损”的机制; 没有“这个 episode 前面几步省下的预算, 留给后面更难步骤用”这种跨步骤的预算结转机制。

5.3.7 ELASTIC ——扩散/流式控制策略的测试时算力调度, 不涉及想象但同属“自适应算力”家族

论文: Li, Swamy, Bisk, Bajcsy, *ELASTIC*, arXiv:2606.31132, 2026.6, CMU。

一句话问题定义: 机器人控制策略 (用扩散/流式生成模型实现) 在测试时可以沿两条方向“砸算力”换质量——**序列方向** (把单个动作的去噪步数变多、算得更精细) 和**并行方向** (同时采样多个 候选动作、用打分器挑最好的)。该往哪个方向砸, 是**依赖当前具体状态的**。原文举了一个具体反例: 拿马克杯任务举例——如果策略不确定“该拿哪个杯子” (这本质是“选哪个模式”的问题), 继续在序列 方向上算得更精细基本没用, 更需要在并行方向上多采样几个候选比较。

术语卡片: 扩散策略 (Diffusion Policy) ——把“预测下一个动作”这件事, 用图像生成里常见的扩散模型来做: 从一堆随机噪声出发, 一步步“去噪”得到一个具体的动作数值, 而不是直接输出 一个确定的动作。这样做的好处是可以自然表达“这个状态下有好几种同样合理的动作”这种多峰 分布, 但代价是需要多步去噪才能得到一个动作, 这正是“该在这个去噪过程上砸多少算力”这个 问题的来源。

结果: 在 LIBERO-10(10 个长时程机器人操作任务集合) 上, 拿一个已经训练好的 SOTA 视觉-语言-动作 (VLA) 模型 pi0.5 做零样本测试 (不重新训练, 只加测试时算力调度)——ELASTIC 拿到 94.0% 成功率、64.5ms 延迟, 而 pi0.5 原始基线是 91.5%/68.7ms, “best-of-N”式暴力采样基线是 95.5%/94.0ms。原文总结: “ELASTIC recovers performance gains equal to Sequential with 6.1% less inference latency” (用序列方向砸算力能拿到的提升, ELASTIC 靠更聪明的调度只用更少的 延迟就拿到了)。真实机器人实验里, “ELASTIC can match the improvements of full BoN scaling with V-GPS while using 34% less inference latency” (能追平“暴力多采样”的提升, 但少花 34% 推理延迟)。


局限性 (原文照录): “the primary limiting factor for the effectiveness of our approach is the learned verifier Q_ϕ . A noisy verifier masks useful signal...hurting meta-policy optimization” (方法有效性的主要瓶颈是学出

来的打分器本身——如果打分器噪声大, 会掩盖有用信号, 反而伤害整体优化)。

5.3.8 RARRL ——LLM 高层推理调用的开关 + 角色 + 预算三元决策, 消融最系统的一篇

论文: *When Should a Robot Think?*, arXiv:2603.16673,2026,CMU+ 东北大学 + 哈佛等多机构。

一句话问题定义: 具身机器人系统调用 LLM 做高层推理会带来巨大延迟——“该不该想、该用哪种 推理角色、该分配多少 预算” 这三个决策合在一起, 在“ 决策层” (不是底层控制层) 学习一个统一的 调度策略。



结果 (在 ALFRED 具身指令跟随基准上, 用真实 LLM 推理测的, 不是模拟延迟):RARRL 相比” 每次 都做完整推理” 的基线, 导航任务成功率 82.7 对比 84.0(略低一点点), 但 LLM 推理耗时从 31.5 秒 降到 **12.3 秒** (降 61%)、token 消耗从 4100 降到 980。“**Budget Shock**” **鲁棒性实验** (模拟 资源突然被削减这种真实场景) 特别值得注意: 资源突降后, 一个” 启发式” 基线的推理调用次数不降 反升 (14.2→15.1, 不会自适应), 而 RARRL 主动降低调用 (11.3→7.6), 同时成功率保持得更高 (74.9 对比 61.8)——这说明真正的自适应调度在” 资源突然变紧张” 这种现实场景里价值更明显。


消融实验 (五项, 是十一篇里做得最系统的一篇): 去掉” 剩余预算” 这个输入, 成功率掉 6.7 个 百分点、且推理频率会升高 (因为策略感知不到资源紧张, 会过度调用); “只用规划者角色” (83.1 分) 不如” 规划者 + 校验者都用” (87.6 分)。

局限性 (原文照录多条): 训练环境是” 抽象/程序化的”, 不是物理仿真器或真实机器人; 主动排除了传感器噪声和执行延迟这些因素 (“we isolate orchestration from sensor noise and actuation delays”); 预算约束是” 软” 的 (不是数学上严格保证不超支的硬约束)。

5.3.9 Finding the Time to Think ——和” 该想多久” 最贴近, 但用完美模拟器 +MCTS, 非生成式 world model

论文:Muppidi, Darwish et al., arXiv:2606.26463,2026.6, 牛津大学 (Foerster 研究组)。

一句话问题定义: 在” 实时” 强化学习场景下——**世界不会等 agent 想清楚**,agent 想得越久, 真实世界就推进得越多——“该想多久” 本身是一个依赖当前状态的元层面决策问题。



术语卡片:SMDP(半马尔可夫决策过程) ——普通 MDP 里每一步花费的” 时间” 都相同 (一步就是一步);SMDP 允许” 一步” 实际花费不同长的真实时间 (比如这次决策” 想了 5 步的时间”、下次决策”想了 1 步的时间”)——这篇论文用 SMDP 来建模” 思考本身要占用环境推进时间” 这件事, 是把 “该想多久” 这个问题写成数学模型的一种方式。

结果 (5 个环境, 拿” 自适应门控” 和” 效果最好的固定思考时长” 比较): 吃豆人 (Pac-Man) 2370 对比 2149(领先 10.3%); 实时版俄罗斯方块领先 **65%**(45.6 对比 27.6); 贪吃蛇 (Snake) 领先 10.9%。原文强调: “random baseline falls well below every fixed-k policy...confirming that *when* to allocate compute matters as much as *how much*” (随机分配思考 时长的基线明显不如任何固定时长策略, 证明” 什么时候该多想” 和” 该想多少” 同样重要)。**可解释性 亮点**: 在实时版俄罗斯方块里, “思考 3 步” 这个选项**从未被策略使用过** (0%)——策略学出的是一种 “要么几乎不想、要么深想” 的两极策略, 不存在中间档。

局限性 (原文三点): 整套方法依赖 MCTS 能在一个**完美的**模拟器上工作 (知道环境的精确规则), 换成 MuZero 那种” 学出来的” 不完美动力学模型是论文自己承认的” 未来工作” ; 门控策略是在一个 “冻结不动” 的底层规划器之上训练的, 两者联合优化仍是开放问题; **没有任何形式化的收敛性/最优性 理论保证**——这一点在后面 Part 6 讲我们自己想补的” 理论空当” 时会再次用到。

5.3.10 ROI-Reasoning —— “跨步预算调度” 机制上最接近的匹配, 但用于 LLM 批量数学推理

论文:Zhao, Qi, Sun, arXiv:2601.03822,2026.1, 中国人民大学。

一句话问题定义: 多道题共享一个严格的全局 token 预算, 该怎么在题目之间分配算力? 这被形式化 成一个叫 **OS-MCKP**(Ordered Stochastic Multiple-Choice Knapsack Problem, 有序随机多选 背包问题) 的经典优化问题——按固定顺序、在代价和收益都不确定的情况下, 做一系列不可逆的决策 (做完一道题的预算分配就不能反悔重来)。

术语卡片: 背包问题 (Knapsack Problem) ——一个经典组合优化问题: 有一个容量有限的背包 和一堆价值、重量各不相同的物品, 该选哪些物品装进背包才能让总价值最大。这里的“物品”是“每道题该投入多少算力”, “背包容量”是总的 token 预算——把“预算该怎么在多个任务间分配”类比成背包问题, 是一种常见且有成熟理论工具支持的建模方式。


结果 (用一个只有 1.5B 参数的小模型, 对比参数量是它上百倍的大模型): 最亮眼的数字——在“最难的题 + 最紧的预算”这个设定下, 经过两阶段训练的模型拿到 **0.93** 分 (满分区间内), 远超 GPT-4o-mini 的 0.32、以及参数量大 450 多倍的 DeepSeek-V3.2(685B) 的 0.49。分题目拆解显示, baseline 方法在“考卷最后一题”上明显比第一题答得差 (说明前面的题目把预算花超了), 而这篇论文 的方法在后面几道题上提升幅度最大——学到的是“为后面的题目预留预算”这种**长程分配策略**。

局限性: 聚焦固定 3 道题的数学推理场景; 用 token 数量代理“成本”, 不能完全捕捉真实世界里的延迟/工具调用/验证等更复杂的成本构成; **没有把经典背包问题的理论最优性证明, 迁移/证明到 这里用强化学习求解的具体方案上**——也就是说, 虽然问题的数学形式是背包问题, 但论文并没有真正 拿到背包问题理论能提供的最优性保证, 这一点在后面 Part 6 讨论“理论保证”这个空当时会再次提到。

5.3.11 World-in-World —— “多候选比较” 这个机制目前做得最完整, 但 ICLR 接收状态未能证实

论文: Zhang, Jiang et al., arXiv:2510.18135, 2025.10, JHU+PKU+Princeton+MIT 等。

一句话问题定义: 现有的 world model 评测大多是“开环”的 (open-loop, 只看生成的画面 质不质量高), 没有一个评测真正测过“生成出来的想象世界, 是否真的能帮 agent 在一个完整的决策 循环里做出更好的选择”。



这个“提案 → 模拟 → 修订”的结构, **比经典的 MPC(模型预测控制) 更通用**——MPC 优化的对象被限制 在“一串动作序列”里, 这里的“修订”阶段可以合成/更新一个全新的决策, 不局限于事先枚举好的 候选集合。

结果 (在论文自己新构造的 4 个闭环任务套件上, 不是套用外部现成 benchmark): 在“主动识别 被遮挡物体”任务上, 闭源模型 Runway Gen4(零样本) 成功率 64.79%; 开源模型里最好的是经过 后训练的 Wan2.2 达 62.43%。**论文自己报告的一个重要发现:** 把后训练数据从 400 条扩到 8 万条, 成功率单调上升, 而且**更大的模型 (14B) 比更小的模型 (1.5B) 从数据增加中获益更多、更晚出现饱和**——原文原话: “scaling action-conditioned post-training is more effective for embodied utility than upgrading the pretrained generator” (针对具体动作场景做后训练扩展, 比单纯升级预训练生成器本身更有效)。

局限性 (原文正文列出四条): 世界模型的泛化能力仍是关键瓶颈 (有时会退回训练时见过的先验、忽略当前具体的动作指令); 长视野规划仍然困难 (缺乏“累积时空历史”的机制); 精确建模“接触 丰富”的交互 (比如机器人抓取时手指和物体的接触细节) 仍然困难。

关于 ICLR 接收状态——本次专项核实: 逐页通读了完整 43 页 PDF(正文 + 参考文献 + 全部 6 个附录), **没有找到任何会议接收信息**——标题页只有普通的 arXiv 日期戳, 没有“Published/Under review as a conference paper at ICLR”这类横幅, 全文也没有 Acknowledgments 致谢段落。**结论:** 以这份 v1 版 PDF 为准, 无法确认它是否被 ICLR 2026 接收、是否是 Oral, 读起来就是一份标准的 arXiv 预印本。这也是一个很好的示范: **引用一篇论文时, 不能想当然认为“看起来很强”就等于“已经被顶会接收”, 需要真的去查证。**

5.3.12 十一个方法一张总表

方法	决策粒度	训练方式	理论保证	核心 benchmark	我们的差异化空间
AVIC	单次二元 gate+ 自治采样	强化学习 (GRPO)	无	SAT-Real / R2R	真正决策价值比较 + 跨步预算
FFDC	单条轨迹信 / 不信	监督二分类	无	RoboTwin+ 真实机器人	多候选比较
Video-T1	树搜索剪枝 (生成质量)	打分器筛选	无	VBench	决策价值而非生成质量
Astra	单次二元 gate+ 自治采样	强化学习 (两阶段 GRPO)	无	MMSI-Bench / MindCube	同 AVIC
ITP	每步选想象深度 K	强化学习 (A2C)	无	ALFWorld 等 4 个	中途止损 + 跨 episode 结转
ELASTIC	去噪步数 + 并行采样	强化学习 (SAC)	无	LIBERO-10+ 真实机器人	非 world model, 间接参照
RARRL	开关 + 角色 + 预算三元	强化学习 (PPO)	无	ALFRED	非 world model, 间接参照
Finding-Time-to-Think	每个决策点选思考时长 k	强化学习 (PPO)	无 (仅问题形式化严谨)	5 个实时游戏	生成式 world model+ 联合优化
ROI-Reasoning	每题解答深度 / 弃权	监督 + 强化学习	无 (所谓 regret 只是经验指标)	GSM8K / MATH / AIME	具身序贯决策场景
World-in-World	多候选提案比较	无 (启发式 / 预训练策略)	无	4 个自建套件	VOC 式反事实差值打分
我们要做的	三个决策点统一	理论驱动 + 训练估计	VOC / 最优停止 (目标)	合成 pilot+ 真实 world model	—

上表最右边“理论保证”这一栏，**十一篇文章没有一篇打勾**——这正是 Part 6 要展开的核心论点。

Part 6. 我们的研究定位：从三轮 Pilot 到 ε -渗透 VOC

6.1 从零讲清楚：什么是“计算的价值” (VOC)、什么是“最优停止”

在讲我们自己做了什么之前，必须先把全项目最核心的数学工具讲透——因为这是十一篇最近邻论文全部没有用到的武器，也是我们提出的新方向的理论基础。

一个日常类比：过马路前要不要看一眼。你走到马路边，有两个选择：(a) 直接走过去；(b) 先花 2 秒钟左右看一眼再走。“看一眼”这个动作，就是一次“计算”（在我们的问题里，“计算”特指“调用 world model 想象一下接下来会发生什么”）——它要花时间（2 秒钟的机会成本），但可能帮你做出更好的决策（如果看到有车冲过来，你会等一等，而不是直接走）。

“看一眼”这件事，值不值得做？这取决于三个量：

1. **看了以后，你的决策能变好多少**——如果这条街你每天走，从来没车，看不看结果都一样，那“看一眼”改变决策的可能性几乎是零。
2. **不看的话，你会怎么决策**——如果不看你也会本能地放慢脚步观察周围，那“正式看一眼”这个动作带来的**额外**信息量可能并不大。
3. **看这一眼要花多少代价**——2 秒钟很便宜，但如果是“停下来等红绿灯变化”这种要花 30 秒的“计算”，代价就高很多。

把这三点写成一个公式，就是 **Value of Computation(计算的价值, 简称 VOC)**——这是 Russell & Wefald 在 1991 年提出的经典理论框架（发表在权威期刊 *Artificial Intelligence* 上，不是 arXiv 论文，因为 1991 年 arXiv 还不存在）：

$$\text{VOC}(c) = \underbrace{\mathbb{E}[\text{做了计算 } c \text{ 之后, 按最优决策能拿到的效用}]}_{\text{看了一眼之后的期望结果}} - \underbrace{\mathbb{E}[\text{不做计算 } c, \text{按当前已知信息决策能拿到的效用}]}_{\text{不看直接走的期望结果}} - \underbrace{\text{cost}(c)}_{\text{做这次计算本身的代价}}$$


该不该做这次计算（在我们的场景里就是“该不该调用 world model 想象一下”）的判据非常简单： $\text{VOC}(c) > 0$ 就做， ≤ 0 就不做——这句话翻译过来就是“如果多算这一步，期望上能让决策变得更好、而且好处大于花费的代价，就值得算；否则就不值得”。

什么时候该停（不只做一次计算，而是可以连续做很多次，比如连续想象好几步）：如果手头还有“计算 1、计算 2、计算 3”这些可以选的计算，理性的做法是每次都挑 **VOC 最大的那个计算去做**，一直做到**所有剩下的计算 VOC 都不再是正的**为止，这时候就应该停下来、直接执行当前已经知道的最优决策——这套“连续决定要不要继续算下去”的理论，叫**最优停止理论** (Optimal Stopping Theory, 经典参考是 Chow, Robbins & Siegmund 1971 年的专著)，数学工具是鞅 (martingale, 一种“下一步的期望值等于当前值”的随机过程，后面 §6.2 会用到)。

这套理论为什么重要，值得专门用一个 Part 来讲：Part 5.3 的十一个最近邻方法，没有一篇显式使用这套框架——它们全部是“设计一个奖励函数，用强化学习 (GRPO/PPO/SAC 等) 训练一个网络去猜‘该不该想’”，这是一种**经验驱动**的做法：好不好用要靠实验验证，没有数学上的保证。VOC/最优停止理论提供的是**理论驱动**的做法：如果能把“该不该想”写成一个显式的 VOC 计算，理论上可以证明这个判断在某种假设下是最优的（或者至少有一个可以量化的误差界）。这条“经验驱动 vs 理论驱动”的分野，正是我们研究定位的核心。

6.2 我们自己的三轮 Pilot 实验

要点: 在提出任何新方法之前, 项目先在一个真实转移函数已知、可以精确算出“标准答案”的合成环境里, 系统测量“想象到底什么时候真的有用”。三轮 pilot 分别测了三个递进的问题, 每一轮都在跑代码之前**预先写下预测** (避免“看到结果再编故事”这种科研上不诚实的做法), 然后诚实报告 预测被证实还是被推翻。



术语卡片：命中率 / 决策改变率 / 帮倒忙率——这是本项目 pilot 实验自己定义三个指标。“决策改变率”指“想象之后，选的动作和不想想象时不一样”的比例；“命中率”指“在决策改变的那些情况里，想象选的新动作确实比原来的动作更接近真实最优 Q^* ”的比例；“帮倒忙率”是命中率的反面——想象改变了决策，但改坏了。三个指标合起来才能完整回答“想象有没有用”：光看“决策改变率”高不能说明想象有用，可能全是在帮倒忙。

第一轮（表格模型）：用真实频次统计学出的表格格式 world model。扫想象深度 H （候选数 $K = 5$ 固定）发现：命中率从 44.0% ($H = 1$) 一路降到 27.2% ($H = 8$)，但决策改变率反而从 10.0% 升到 23.1%——**想得越深，决策改变得越多，但改得越来越不准。**

数学推导（严格证明，不是拍脑袋观察）：因为两个策略共享同一个不完美的 LearnedWorldModel——想象 rollout 的续跑策略和 bootstrap 用的都是同一个 $\hat{V}$ ，根据 Bellman 不动点方程，想象 rollout 的期望值会精确“telescope”（逐层抵消）回 $\hat{V}$ 自己的一步展开值，**理论上和 H 完全无关**。用鞅的全方差公式可以进一步加强这个证明：定义 $Y_t = \mathbb{E}[G_H | \mathcal{F}_t]$ 为条件期望过程，这是一个鞅，全方差公式 $\text{Var}(Y_H) = \sum_{t=1}^H \mathbb{E}[\text{Var}(Y_t | \mathcal{F}_{t-1})]$ 严格非负、非递减——**这解释了“想得越深、决策改变得越多”这个观测到的现象是数学上必然的，方差累积，不是巧合，更不是“想象真的带来了新洞察”。**

第二轮（神经网络集成模型）：换成 5 个手写的小型神经网络组成的集成模型，回答“第一轮发现的发现是不是表格模型独有的巧合”。决策改变率恒定在 65%~81% 高位（神经网络预测天然更“软”，注入更多采样方差，这个量级比表格模型的 10%~36% 高得多，反而更接近真实 DreamerV3/TD-MPC2 这类系统会有的效应）。还测试了一个“member 模式”（想象采样时随机抽一个集成里的成员，让想象“看到”基线看不到的集成分歧）——**结果没有带来预期的改善，这是一条负结果，把“多掌握的信息必须是决策相关的”这条教训精确化了**：哪怕是理论上货真价实的认知不确定性（epistemic uncertainty），只要这份“新信息”和真正的决策目标无关，也救不回来。

第三轮（task-conditioning）：给想象一个真正决策相关的信息优势——让想象“知道”这一局真实的任务目标，而基线不知道。三个候选目标上，想象的命中率**全部反超基线**（汇总 82.0% vs 63.7%，领先 18.3 个百分点，零例外）——这是三轮 pilot 里第一次出现的正向发现。**一个意外的深层发现**：即使是“不知道真实目标”的对照组，命中率也比前两轮同源实验高很多（57%~73% vs 前两轮的 30%~50%）——推导原因是实验设计里“即时奖励一直用真实目标计算、只有 bootstrap 价值函数是过时的”这个选择本身，让更深的 rollout 在“跌回”过时的 bootstrap 之前，先吃到了更多真实目标的奖励信号，**这个渗透程度会随想象深度 H 增加而增加——这是全篇最重要的一条经验发现**：给想象多少真实任务信息，不是“有”或“没有”的开关式判断，是一个连续的程度问题，哪怕只打开“奖励可观测”这一个通道、其他通道不动，想象也能捡到部分真实信号。

6.3 一次重要的自我纠正

这是二次深挖调研（2026-07）里最重要的一次修正，必须诚实讲清楚。**第一轮和第二轮 pilot 的“发现”（同源想象 = 噪声、无关随机性救不回来），核心原理正是 Russell & Wefald 1991 年 VOC 理论的直接推论——“当所有可用计算的 VOC 都不为正，应该立即执行当前 belief 下的最优动作”，数学上就是“计算不能改变决策，则其期望价值恒为零”。**这条结论早就被 Hay, Russell, Tolpin, Shimony 的论文 *Selecting Computations* (arXiv:1207.5879, UAI 2012 会议论文，而且这篇论文本来就在我们自己的文献库里！) 形式化到贝叶斯选择问题的层面。


这意味着什么：如果我们把研究的核心贡献叙事锚定在“我们发现了想象要有用必须有信息优势”这件事本身，任何熟悉这条文献脉络的审稿人几乎肯定会指出——这是在重新发明一个 30 年前就有的轮子，这正是“desk reject”（编辑不送审直接拒稿）最典型的成因之一。**这个问题必须现在改口径，不能等审稿人指出来才改。**

但这不代表第一、二轮 pilot 没有价值：我们做的是“第一次在‘测试时想象 + 现代 world model’这个具体场景里，把一个 30 年前的抽象原理用严格数学（鞅的全方差分解）钉实、做出可复现的受控实验”——这是合法的**理论基线**与**阴性对照**贡献，不是新发现，诚实讲清楚这一点，本身就是向审稿人证明我们做过认真的文献调研。

真正站得住”新发现”这个说法的，是第三轮的发现（信息优势的渗透是连续的、分通道的）——穷尽检索没有找到任何先例把“信息优势是连续渐变的”这个视角系统性地引入经典 VOC 理论。

6.4 三条独立证据线收敛到同一个方法论空当


1. **证据线 1(竞争格局的共性):**§5.3.12 总表最右列——十一篇最近邻方法，**没有一篇在“理论保证”上打勾**，全部靠强化学习训练一个经验式门控网络。
2. **证据线 2(已经有人在摸，但没碰到我们的场景):**二次深挖核实到一篇 *Cognitive Friction*(arXiv:2603.30031,2026.3) 用 HJB(Hamilton-Jacobi-Bellman, 一种源自最优控制理论、描述“最优策略应该满足什么微分方程”的经典工具) 启发的最优停止边界，处理“该不该继续查询工具”这个决策——但应用场景是通用工具调用 agent，完全没有涉及 world model/想象这个具体设定。这篇论文的存在证明“理论化门控”这条路不是我们凭空想象出来的死胡同，只是还没人把它接到 world model 想象这个具体问题上。
3. **证据线 3(我们自己已经具备的实证基础):**第一轮 pilot 的 Bellman telescoping 论证本身就是 VOC 理论在“同一模型多次采样”这个特殊情形下的严格实例化；第三轮 pilot 揭示了经典 VOC 理论一个没被充分处理的维度——**经典 VOC/最优停止理论普遍隐含假设“信息优势”是二元的(要么有、要么没有)**，而我们的实测表明信息优势的渗透是连续、分通道的。



6.5 具体提案: 把经典二元 VOC 推广成 ϵ -渗透 VOC

给想象 rollout 涉及的每个“信息通道” c (即时奖励、value bootstrap、转移模型本身、continuation policy) 都赋一个渗透率 $\epsilon_c \in [0, 1]$, 表示这个通道携带了“基线不掌握的真实任务信息”的程度—— $\epsilon_c = 0$ 表示这个通道和基线完全同源


(没有 额外信息), $\varepsilon_c = 1$ 表示这个通道完全知道真实任务信息。当所有通道的 $\varepsilon_c = 0$ 时, 理论预测应该精确退化到第一轮 pilot 已经证明的 Bellman telescoping 结果——**这不是被推翻, 是这个更一般框架的一个特例。**



我们的三轮 pilot, 其实已经是这个 ε 空间里的几个具体采样点: 表格/神经网络 pilot 全部 $\varepsilon = 0$; member 模式引入了一个 $\varepsilon > 0$ 但和决策无关的通道 (验证了 " $\varepsilon > 0$ 不等于 $VOC > 0$ ", 信息必须是真的和决策相关); task-conditioning pilot 是 $\varepsilon_{\text{reward}}$ 恒为 1、 $\varepsilon_{\text{bootstrap}}$ 从 0 变到 1 的一条轨迹, 63.7% 和 82.0% 是两个具体的、真实测出来的 calibration 数据点。需要形式化并检验的核心问题: VOC 作为 $\{\varepsilon_c\}$ 和想象深度 H 的函数, 具体的函数形式是什么? 能不能 给出理论上可以求解、或者至少可以数值刻画的" 最优停止深度" $H^*(\varepsilon)$?

6.6 我们要怎么才能超越现有 SOTA

不要走的路: 不要把方法贡献定位成" 又一个用强化学习训练的想象门控" ——这条路已经拥挤 (Astra/ITP/AVIC 都在这条赛道), 资源更强的团队会更快把它做大做强, 一个时间有限的小团队在 纯经验式路线上没有速度优势。




1. **理论保证是十一篇竞品共同缺失的维度**——不需要在“想象机制本身”上比谁的工程更精巧，只需要在“门控决策有没有可证的最优性/误差界”这一个维度上做到竞品都没做的事。
2. **受控 ground-truth 验证方法论是我们独有的资产**——十一篇竞品里,ELASTIC/RARRL 明确 承认“没有引用外部 SOTA 做对比, 只做内部对照”；我们的合成环境 + 精确 value iteration 裁判, 是目前唯一能够精确判断“想象选的动作是否真的更优”的评测协议。
3. **task-conditioning pilot 的 calibration 数据已经是一个具体的、可扩展的锚点**——不是空谈“我们要做理论”，而是已经有 63.7%/82.0% 这两个真实数字可以拿来验证任何提出的 $VOC(\epsilon, H)$ 函数形式对不对。
4. **信息通道分解这个视角, 现有十一篇论文没有一篇采用**——它们都把“该不该想”当一个整体 决策, 没有拆解“想象内部不同信息来源各自贡献了多少”。

6.7 还未解决的问题（如实列出，不回避）

1. **理论推导本身可能推不出干净的闭式解**——渐变信息 VOC 这个问题, 即使在经典决策论文献 里也可能有已知的困难结果, 能不能拿到“哪怕不完美但站得住”的理论结果, 是最大的不确定性。
2. **即使理论成立, “用网络估计通道级 $\epsilon_c(t)$ ”这个训练目标本身需要重新设计**, 理论优雅不等于实现容易。
3. **需要把 pilot 从 32 状态的合成格子世界搬到真实 world model(DreamerV3/TD-MPC2) 上 重新验证**——高维环境里“信息通道”的定义本身可能更模糊。
4. World-in-World 的 ICLR 接收状态、部分理论补强文献 (F2 组后 6 篇) 的逐字核验尚未完成。
5. **严格的“零信息泄露”三方对照组** (让即时奖励也故意用默认目标计算) 仍未做, §6.2 第三轮 pilot 的机制推导目前基于间接证据, 不是独立实验验证。
6. 这次调研没有找到“渐变信息通道 VOC 延伸”这个具体理论问题的任何已有工作, 但这是“未找到”而非“确认不存在”的判断, 不排除换一个理论社区 (信息论/控制论) 搜索会有新发现。

Part 7. 时间线与开放问题



需要会议明确拍板的问题 (汇总 Part 6 全部开放项, 不在本文档里下结论):

1. ϵ -渗透 VOC 这个方向, 从理论背景判断, 能不能在有限时间内拿到“哪怕不完美但站得住”的理论结果?
2. 如果理论路线可行, 是否需要收窄成“理论框架 + 合成环境验证”这一半, 真实 world model 验证作为后续工作?
3. 如果理论风险太高, §6.6 提到的“消融研究框架”降级方案是否可以接受?
4. World-in-World 的 ICLR 接收状态、理论补强文献里尚未逐字核验的部分, 谁来做、什么时候做?

5. 10 个候选 idea(见 [00-brainstorm-10-ideas.md](#)) 里最终 选哪 1-2 个并行推进——本文档不做决定, 决定权按既定安排留给会议。
-

附录 A. 完整术语与缩写表

按类别分组, 方便按主题查找; 第一次在正文出现的位置已经给过解释, 这里是压缩版方便随时回查。

A.1 强化学习基础

词	解释
RL(强化学习)	Agent 通过试错、依据反馈信号调整行为的机器学习范式
Agent(智能体)	做决策、执行动作的主体
Environment(环境)	Agent 所处、会因动作而改变的外部世界
State / Observation(状态 / 观测)	环境当前的样子
Action(动作)	Agent 可以对环境施加的操作
Reward(奖励)	环境对动作的数值反馈,agent 的目标是最大化长期累积奖励
Policy(策略)	从状态到动作的决策规则 / 网络, 记作 π
Value Function $V(s)$ (价值函数)	从状态 s 开始按某策略走下去的长期期望累积奖励
Q-function $Q(s, a)$ (动作价值函数)	在状态 s 先做动作 a 、之后按策略走下去的长期期望累积奖励
MDP(马尔可夫决策过程)	$(\mathcal{S}, \mathcal{A}, P, R, \gamma)$ 五元组, 下一状态只依赖当前状态和动作
POMDP(部分可观测 MDP)	Agent 不能直接看到完整真实状态, 只能看到部分观测的 MDP 变体
Bellman 方程 / 不动点	价值函数满足的递归一致性方程, 是几乎所有 RL 算法的理论基础
Value Iteration(价值迭代)	对 Bellman 方程反复迭代直到收敛、精确算出最优价值函数的经典算法
折扣因子 γ	未来奖励打的折扣, 越接近 0 越“短视”

A.2 World Model 专有概念

词	解释
World Model(世界模型)	学出来的、近似真实环境转移 / 奖励函数的模型, 记作 $\hat{P}, \hat{R}$
Model-based RL(基于模型的强化学习)	用 world model 辅助决策 / 训练的 RL 范式
Model-free RL(无模型强化学习)	直接在真实环境里试错学策略, 不建 world model
想象 / Rollout	用 world model(而非真实环境) 展开模拟出的一条轨迹
Horizon(H , 想象深度 / 规划视界)	想象 / 规划展开了多少步
RSSM(循环状态空间模型)	Dreamer 系列 world model 的核心结构, 含表示 / 转移 / (奖励) 预测三部分
隐空间 (Latent Space) / 隐状态 / 隐变量	观测被压缩后的抽象表示空间, 不要求能还原出原始画面
VAE(变分自编码器)	一种把高维数据压缩成低维向量、又能从向量还原回去的生成模型
Tokenizer(分词器)	把连续信号 (图像 / 视频) 切分 / 压缩成离散“词元”序列的模块
自回归模型 (Autoregressive Model)	逐个生成序列元素、每一步依赖之前已生成内容的生成模型
扩散模型 (Diffusion Model)	从随机噪声出发逐步“去噪”生成数据的生成模型
去噪步数 (Denoising Steps)	扩散模型生成一个样本需要迭代的步数, 步数越多通常质量越好但越慢

词	解释
隐动作模型 (Latent Action Model)	不靠人工标注、自己从视频里学出一套“隐藏动作空间” 的模块 (如 Genie)

A.3 测试时计算与规划

词	解释
测试时计算 (Test-time Compute)	部署 / 推理阶段 (而非训练阶段) 额外花费的计算量
Planning(规划)	行动前先用模型“预演” 多种可能性再决策
MCTS(蒙特卡洛树搜索)	反复模拟 + 回传更新统计量、逐步聚焦有希望分支的树搜索算法
PUCT / UCB	MCTS 里平衡“探索新分支” 和“利用已知好分支” 的打分公式
MPC(模型预测控制)	规划一整段动作但只执行第一步、随后重新规划的控制范式
CEM(交叉熵方法)	采样候选方案、保留表现最好的一批、逐步收窄采样分布的搜索算法
MPPI	和 CEM 类似、用加权平均迭代更新候选分布的规划算法
Bootstrap / 终值函数 (Terminal Value Function)	用价值函数估计“想象截断点之后” 还没算到的长期回报
Self-Consistency(自洽性)	同一模型对同一输入独立重复采样多次、再综合 / 挑选的技巧
Best-of-N	生成 N 个候选、用打分器挑最好一个的最基础范式
Ablation(消融实验)	去掉 / 替换方法的某个部件, 观察效果变化以证明该部件的作用
SOTA	State-of-the-Art, 当前公开报告里最好的效果

A.4 不确定性与信息

词	解释
Uncertainty(不确定性)	模型对自己预测把握程度的量化
Epistemic Uncertainty(认知不确定性)	因为数据 / 知识不够导致的不确定性, 原则上可通过多学习 / 多观测降低
Aleatoric Uncertainty(偶然不确定性)	环境本身固有的随机性, 再怎么多学习也降不下去
Ensemble(集成)	训练多个独立模型, 用它们的平均 / 分歧来估计预测和不确定性
Disagreement(分歧)	集成中多个模型对同一输入预测不一致的程度, 常用作不确定性代理
MC-Dropout	测试时也保持 dropout 开启、多次前向采样来近似不确定性的技巧
Conformal Prediction(保形预测)	用校准集给出有统计覆盖保证的预测集合 / 区间的方法

A.5 训练算法

词	解释
PPO(近端策略优化)	一种常用、稳定的强化学习策略梯度算法
GRPO / Dr.GRPO	PPO 的变体, 对同一输入采样一组输出、组内相对比较来算优势值
SAC(Soft Actor-Critic)	一种鼓励策略保持一定随机性 / 探索性的强化学习算法
A2C(Advantage Actor-Critic)	用优势函数指导更新的经典 actor-critic 算法
KV Cache	复用之前算过的中间注意力结果、避免重复计算的工程技巧

A.6 数学与理论工具

词	解释
VOC(计算的价值, Value of Computation)	量化“多做一次计算”值不值得的经典理论框架 (Russell & Wefald 1991)
VOI(信息的价值, Value of Information)	VOC 的更早期版本, 专指“获得某条信息”的价值
最优停止理论 (Optimal Stopping Theory)	研究“该在什么时候停止继续观察 / 计算”的经典数学理论
鞅 (Martingale)	一种“下一步的条件期望等于当前值”的随机过程, 是很多停止理论证明的工具
全方差公式 (Law of Total Variance)	$\text{Var}(Y) = \mathbb{E}[\text{Var}(Y X)] + \text{Var}(\mathbb{E}[Y X])$, 本项目用它证明想象方差随深度非递减
Submodularity(次模性)	一种“边际收益递减”的集合函数性质, 满足时贪心算法有理论近似保证
HJB 方程 (Hamilton-Jacobi-Bellman)	最优控制理论里描述“最优策略应满足什么微分方程”的经典工具
SMDP(半马尔可夫决策过程)	允许每一步花费不同长真实时间的 MDP 变体
POIMDP	ITP 论文提出的 POMDP 变体, 显式加入“可以调用 world model 想象”这个能力
背包问题 (Knapsack Problem)	在容量约束下挑选价值最大的物品组合的经典优化问题
OS-MCKP	Ordered Stochastic Multiple-Choice Knapsack Problem, ROI-Reasoning 论文用来形式化“多题共享预算”的模型

A.7 评测、会议与常见缩写

词	解释
arXiv	一个论文预印本平台, 论文可以在正式会议 / 期刊评审通过之前先在这里公开
ICLR / NeurIPS / ICML / UAI / ACL / EMNLP	机器学习 / 人工智能领域的主要学术会议
Benchmark(评测基准)	用来衡量、比较不同方法效果的标准数据集 / 任务集合
Zero-shot(零样本)	不针对目标任务做任何额外训练 / 微调, 直接测试
VLM / LLM	Vision-Language Model(视觉语言模型) / Large Language Model(大语言模型)

A.8 本项目自造术语 (pilot 实验专用)

词	解释
决策改变率	想象之后选的动作和不想象时不一样的比例
命中率	决策改变的情况里, 想象选的新动作确实更接近真实最优 Q^* 的比例
帮倒忙率	决策改变的情况里, 想象选的新动作反而更差的比例 (命中率的反面)
Task-conditioning(任务条件化)	让想象过程能“看到”基线看不到的真实任务目标信息
ϵ -渗透 VOC	本项目提出的方向: 给每个信息通道赋一个连续渗透率 $\epsilon_c \in [0, 1]$, 推广经典二元 VOC 理论

参考文献索引

Part 3 历史脉络核实的 9 篇经典论文:World Models(1803.10122)、PlaNet(1811.04551)、Dreamer(1912.01603)、DreamerV2(2010.02193)、MuZero(1911.08265)、TD-MPC(2203.04955)、TD-MPC2(2310.16828)、Genie(2402.15391)、GameNGen(2408.14837)。

Part 5 逐字通读全文 (含附录) 的 11 个核心最近邻方法论文:AVIC(2602.08236)、FFDC(2605.06222)、Video-T1(2503.18942)、DreamerV3(2301.04104)、Astra(2606.06476)、ITP(2601.08955)、ELASTIC(2606.31132)、RARRL(2603.16673)、Finding-the-Time-to-Think(2606.26463)、ROI-Reasoning(2601.03822)、World-in-World(2510.18135)。

Part 6 理论锚点:Russell & Wefald(1991,VOC 框架原始出处)、Hay et al. *Selecting Computations*(1207.5879,UAI 2012)、Cognitive Friction(2603.30031)。**诊断性证据:** Current Agents Fail to Leverage World Model(2601.03905)。

完整 68 篇文献库 (含 A-F 六个 track、每篇标注核心机制与相关性) 见 [papers/INDEX.md](#)。更高信息密度、面向已有背景读者的版本见 [05-full-technical-briefing.md](#); 本文档所有 Part 5-6 数字的原始核验记录见 [03-novelty-competitive-landscape.md](#)。